


Analyse Numérique

Basé sur le cours de Maude Girardin

Thélio Geiser

Spring 2026



Avertissement et Responsabilité

Ce document constitue une retranscription de notes de cours prises manuellement, dont la mise en forme en $\text{\LaTeX}$ a été générée par une intelligence artificielle (IA).

Limites du document : Bien qu'une vérification de la syntaxe et des équations ait été demandée à l'IA, le contenu n'a pas fait l'objet d'une relecture humaine exhaustive. Des erreurs conceptuelles, typographiques ou des hallucinations numériques peuvent subsister dans le code source ou les démonstrations.

Contact : Pour toute erreur critique détectée, suggestion de correction ou problème de compilation, veuillez contacter l'auteur à l'adresse suivante :

thelio.geiser@epfl.ch

Ou ouvrez une *Issue* sur Github

https://github.com/Examera1005/Analyse_Numerique

Table des matières

1	Semaine 1 : Introduction aux Méthodes Itératives	7
1.1	Méthode du Point Fixe	7
1.2	Méthode de Newton	8
1.3	Variantes : Sécante et Corde	8
2	Semaine 2 : Méthode du Point Fixe et Méthode de Newton	10
2.1	La Méthode du Point Fixe	10
2.2	Convergence de la Méthode de Newton (1D)	11
2.3	Méthode de Newton pour les Systèmes Non Linéaires	12
3	Semaine 3 : Résolution de systèmes linéaires	14
3.1	Introduction : Résolution de systèmes linéaires	14
3.2	Systèmes triangulaires	14
3.2.1	Système triangulaire inférieur	14
3.2.2	Système triangulaire supérieur	14
3.3	Factorisation LU	15
3.3.1	Principe et élimination de Gauss	15
3.3.2	Avantages de la décomposition $L \cdot U = A$	15
3.3.3	Pivotage partiel	16
3.4	Matrice Symétrique Définie Positive (SDP)	17
3.5	Un exemple d'application : Les moindres carrés	17
4	Semaine 4 : Méthodes Itératives et Résolution de Systèmes Linéaires	19
4.1	Méthodes de Richardson	19
4.2	Méthodes itératives pour les matrices SDP	20
4.3	Méthode du Gradient (à pas optimal)	22
4.4	Méthode du Gradient Conjugué (GC)	22
5	Semaine 5 : Interpolation	24

5.1	Interpolation polynomiale	24
5.2	Base de Lagrange	24
5.2.1	Construction de la base de Lagrange	25
5.3	Interpolation de fonction	26
5.4	Interpolation par intervalles (par morceaux / Splines)	26
6	Semaine 6 : Intégration Numérique	28
6.1	Premières formules de quadrature	28
6.2	Formalisme général	29
6.3	Exemples	29
6.4	Estimation d'erreur	30
7	Semaine 7 : Dérivation Numérique	32
7.1	Introduction à la dérivation numérique	32
7.2	Convergence d'une formule de différences finies : exemples	33
7.3	Formules plus générales	34
7.4	Dérivées d'ordre supérieur	35
7.5	Dérivées numériques et erreurs d'arrondis	36
8	Semaine 8 : Équations Différentielles Ordinaires (1er ordre)	37
8.1	Introduction et Problème de Cauchy	37
8.2	Existence et Unicité : Exemples et Contre-exemples	37
8.3	Méthodes Numériques d'Approximation	38
8.3.1	Approche par Dérivation Numérique (Différences Finies)	39
8.3.2	Approche par Intégration Numérique	39
9	Semaine 9 : EDOs scalaires et Systèmes	41
9.1	Méthodes à 1 pas et Erreur	41
9.2	Stabilité	42
9.3	Systèmes d'EDOs	42
9.4	EDOs d'ordre supérieur	42

10 Semaine 10 :	43
10.1 Méthode des différences finies	43
10.2 Erreur numérique	44
10.3 Conditions aux limites de Neumann	45
10.4 Ajout d'un terme linéaire de réaction	46
10.5 Ajout d'un terme non-linéaire	47
11 Équation de la chaleur-Semaine 11	48
11.1 Problème modèle	48
11.2 Approximation numérique	49
11.2.1 Schéma d'Euler progressif (explicite)	50
11.2.2 Schéma d'Euler rétrograde (implicite)	51
11.3 Stabilité	52
11.4 Convergence	52
12 Semaine 12-Transport et Ondes	53
12.1 Équation de transport	53
12.1.1 Approximation numérique	53
12.1.2 Schéma décentré amont (Upwind)	54
12.1.3 Stabilité	55
12.2 Équation des ondes	56
12.2.1 Schéma numérique (Différences finies centrées)	57
12.2.2 Traitement de la vitesse initiale (Point fictif)	58
12.2.3 Stabilité et Erreur (Équation des ondes)	58
13 Semaine 13 - Introduction aux Éléments Finis	60
13.1 Limites de la méthode des différences finies	60
13.2 Méthode des éléments finis et formulation faible	61
13.3 Méthode de Galerkin	62
13.4 Choix des fonctions de base et fonctions chapeau	64

13.5 Calcul de la matrice de rigidité et du second membre	65
13.6 Comparaison : Éléments Finis (EF) vs Différences Finies (DF)	66
13.6.1 Synthèse graphique : DF vs EF	66

1 Semaine 1 : Introduction aux Méthodes Itératives

1.1 Méthode du Point Fixe

Théorie du Cours (Pages 3-5)

L'idée (Itération de Picard) est de transformer $f(x) = 0$ en une équation équivalente $x = \Phi(x)$.
L'algorithme est défini par la suite : $x^{k+1} = \Phi(x^k)$.

Conditions d'Existence et de Convergence

D'après les notes de cours (p. 4), pour garantir la convergence, nous avons besoin de deux propriétés sur l'intervalle $I = [a, b]$:

Théorème : Du Point Fixe (Convergence Globale)

Soit $\Phi : I \rightarrow \mathbb{R}$ telle que :

1. **Stabilité** : $\Phi(I) \subset I$ (Pour tout $x \in [a, b]$, $\Phi(x) \in [a, b]$).
2. **Contraction** : Φ est contractante, c'est-à-dire qu'il existe $L < 1$ tel que $|\Phi'(x)| \leq L$ pour tout $x \in I$.

Alors :

- Il existe un unique point fixe $x^* \in I$.
- La suite converge vers x^* pour n'importe quel point de départ $x^0 \in I$.

Convergence Locale (Théorème d'Ostrowski)

Si on ne peut pas vérifier les conditions sur tout l'intervalle, le cours (p. 5) cite le théorème d'Ostrowski :
Si x^* est un point fixe et que $|\Phi'(x^*)| < 1$, alors il existe un voisinage autour de x^* dans lequel la méthode converge.

Types de Convergence (Série 1, Ex 1a)

Le comportement dépend du signe de $\Phi'(x)$:

- **Monotone** : $0 < \Phi'(x) < 1$. L'erreur diminue sans changer de signe.
- **Oscillante** : $-1 < \Phi'(x) < 0$. L'erreur change de signe à chaque itération (spirale).

Application (Exercice 1b)

Soit $\Phi_1(x) = 1 - \sin(x)$ avec $x^0 = 0.05$.

- $x^1 = 1 - \sin(0.05) \approx 0.95002$
- $x^2 = 1 - \sin(0.95002) \approx 0.18658$

Analyse : $\Phi_1'(x) = -\cos(x)$. Comme $-1 < -\cos(x) < 0$ sur l'intervalle, la convergence est oscillante (confirmé par le passage de 0.05 à 0.95 puis 0.18).

1.2 Méthode de Newton

Dérivation par Taylor

Le cours (p. 2) introduit Newton en cherchant le zéro de l'approximation linéaire de f . Développement de Taylor de f autour de x^k :

$$f(x) \approx f(x^k) + f'(x^k)(x - x^k)$$

On cherche x tel que cette approximation soit nulle ($0 = f(x^k) + f'(x^k)(x - x^k)$), ce qui donne :

$$x^{k+1} = x^k - \frac{f(x^k)}{f'(x^k)}$$

Lien avec le Point Fixe

Le cours (p. 3) note que Newton peut être vue comme une méthode de point fixe avec :

$$\Phi(x) = x - \frac{f(x)}{f'(x)}$$

Pour que Newton converge, il faut donc que $|\Phi'(x^*)| < 1$. Calculons $\Phi'(x)$:

$$\Phi'(x) = 1 - \frac{(f'(x))^2 - f(x)f''(x)}{(f'(x))^2} = \frac{f(x)f''(x)}{(f'(x))^2}$$

Au point fixe (la solution), $f(x^*) = 0$. Donc $\Phi'(x^*) = 0$. Comme $0 < 1$, la méthode converge très vite (convergence quadratique) près de la solution.

Le Problème du Tonneau (Exercice 2)

On cherche la hauteur $h = r(1 - \cos(\alpha))$. L'équation dérivée du volume est :

$$f(\alpha) = \alpha - \frac{1}{2} \sin(2\alpha) - \frac{V}{lr^2} = 0$$

Dérivée pour Newton : $f'(\alpha) = 1 - \cos(2\alpha)$.

Note : Attention à $f'(0) = 0$. Il faut choisir $\alpha^0 \neq 0$.

1.3 Variantes : Sécante et Corde

Le cours mentionne (p. 3) l'idée générale d'approcher f par une droite de pente q^k :

$$x^{k+1} = x^k - \frac{f(x^k)}{q^k}$$

Comparaison des Méthodes (Exercice 3)

Application à l'équation de Kepler (citée en p. 2 du cours comme exemple de $f(x) = 0$) :

$$M = E - e \sin(E)$$

Méthode	Pente q^k	Ordre (Vitesse)	Commentaire
Newton	$f'(x^k)$ (Tangente)	$p = 2$ (Quadratique)	Très rapide, nécessite dérivée.
Sécante	$\frac{f(x^k) - f(x^{k-1})}{x^k - x^{k-1}}$ (Sécante)	$p \approx 1.618$	Rapide, pas de dérivée analytique.
Corde	$f'(x^0)$ (Constante)	$p = 1$ (Linéaire)	Lente, très stable.

2 Semaine 2 : Méthode du Point Fixe et Méthode de Newton

2.1 La Méthode du Point Fixe

L'objectif de cette méthode est de trouver une racine d'une équation $f(x) = 0$ en la reformulant sous la forme équivalente $x = \Phi(x)$. Le scalaire x^* est appelé **point fixe** de la fonction Φ .

Définition : Itération du Point Fixe

À partir d'une estimation initiale x^0 , la suite des approximations successives est définie par la relation de récurrence :

$$x^{k+1} = \Phi(x^k)$$

Théorème : (Ostrowski) : Condition de Convergence

Soit x^* un point fixe d'une fonction Φ continûment différentiable ($\Phi \in C^1$).

Si $|\Phi'(x^*)| < 1$, alors il existe un voisinage de x^* tel que, pour tout point de départ x^0 choisi dans ce voisinage, la suite définie par $x^{k+1} = \Phi(x^k)$ converge **linéairement** vers x^* .

Explication / Idée : Factuelle : Critère d'arrêt

Dans la pratique, on ne connaît pas x^* . Comment savoir quand s'arrêter ? Vos notes étudient la validité de la distance entre deux itérations consécutives : $|x^{k+1} - x^k|$.

Évaluons la distance entre x^k et la vraie solution x^* :

$$x^k - x^* = x^k - \Phi(x^k) + \Phi(x^k) - \Phi(x^*)$$

Par approximation au premier ordre de Taylor (ou accroissements finis) autour de x^k , on a $\Phi(x^k) - \Phi(x^*) \approx \Phi'(z^k)(x^k - x^*)$. En sachant que $x^{k+1} = \Phi(x^k)$:

$$x^k - x^* \approx (x^k - x^{k+1}) + \Phi'(z^k)(x^k - x^*)$$

$$(1 - \Phi'(z^k))(x^k - x^*) \approx x^k - x^{k+1}$$

On obtient donc l'estimation de l'erreur absolue :

$$|x^k - x^*| \approx \frac{|x^{k+1} - x^k|}{|1 - \Phi'(z^k)|}$$

Conclusion : Si $|\Phi'(x^*)| \ll 1$, le dénominateur est proche de 1. L'écart $|x^{k+1} - x^k|$ est donc un excellent indicateur mathématique de la véritable erreur $|x^k - x^*|$, ce qui justifie son utilisation comme critère d'arrêt.

Algorithme / Méthode : Méthode du Point Fixe

```
Données : x_0, tol, max_it,  $\Phi$ 
x = x_0
k = 0
inc = tol + 1
```

```
Tant que (inc > tol et k < max_it) faire
    x_new =  $\Phi(x)$ 
```

```

inc = |x_new - x|
x = x_new
k = k + 1
Fin Tant que

```

2.2 Convergence de la Méthode de Newton (1D)

La méthode de Newton est une méthode de recherche de zéros ($f(x) = 0$) qui utilise la dérivée pour construire une tangente à chaque itération.

Définition : Itération de Newton

La suite est définie par :

$$x^{k+1} = x^k - \frac{f(x^k)}{f'(x^k)}$$

Ceci équivaut à une méthode de point fixe où la fonction d'itération est $\Phi_N(x) = x - \frac{f(x)}{f'(x)}$.

Théorème : Convergence de Newton

Soit $f \in C^2(\mathbb{R})$. Supposons que $f(x^*) = 0$ (racine exacte) et que $f'(x^*) \neq 0$ (la racine est simple). Alors, il existe un voisinage $\delta > 0$ tel que si $x^0 \in [x^* - \delta, x^* + \delta]$:

1. La suite x^k converge vers x^* .
2. La convergence est **quadratique**.

Explication / Idée : Preuve Factuelle 1 : Condition d'Ostrowski

Calculons la dérivée de la fonction d'itération $\Phi_N(x)$ en utilisant la règle du quotient :

$$\Phi'_N(x) = 1 - \frac{f'(x)f'(x) - f(x)f''(x)}{(f'(x))^2} = 1 - 1 + \frac{f(x)f''(x)}{(f'(x))^2} = \frac{f(x)f''(x)}{(f'(x))^2}$$

Évaluons cette dérivée au point fixe x^* :

$$\Phi'_N(x^*) = \frac{f(x^*)f''(x^*)}{(f'(x^*))^2}$$

Puisque par définition $f(x^*) = 0$ et $f'(x^*) \neq 0$, on obtient strictement $\Phi'_N(x^*) = 0$.

Comme $0 < 1$, le théorème d'Ostrowski garantit la convergence locale. Mieux encore, une dérivée nulle au point fixe est la condition mathématique nécessaire pour obtenir une convergence d'ordre supérieur (quadratique).

Explication / Idée : Preuve Factuelle 2 : Ordre Quadratique via Taylor

Nous voulons démontrer qu'il existe une constante $C > 0$ telle que $|x^{k+1} - x^*| \leq C|x^k - x^*|^2$. Exprimons $f(x^*)$ par un développement de Taylor à l'ordre 2 autour de x^k :

$$f(x^*) = f(x^k) + f'(x^k)(x^* - x^k) + \frac{f''(z^k)}{2}(x^* - x^k)^2 = 0$$

(où z^k est compris entre x^k et x^*). Divisons l'équation par $f'(x^k)$:

$$\frac{f(x^k)}{f'(x^k)} + (x^* - x^k) + \frac{f''(z^k)}{2f'(x^k)}(x^* - x^k)^2 = 0$$

Isolons les termes linéaires :

$$-\frac{f(x^k)}{f'(x^k)} - x^k + x^* = -\frac{f''(z^k)}{2f'(x^k)}(x^* - x^k)^2$$

Or, par définition de l'itération de Newton, on sait que $x^{k+1} = x^k - \frac{f(x^k)}{f'(x^k)}$, donc $x^{k+1} - x^k = -\frac{f(x^k)}{f'(x^k)}$.

En substituant :

$$x^{k+1} - x^* = \frac{f''(z^k)}{2f'(x^k)}(x^k - x^*)^2$$

En passant aux valeurs absolues, on obtient la majoration de l'erreur :

$$|x^{k+1} - x^*| \leq C|x^k - x^*|^2 \quad \text{avec} \quad C = \frac{\max |f''(x)|}{2 \min |f'(x)|}$$

2.3 Méthode de Newton pour les Systèmes Non Linéaires

On souhaite maintenant trouver les racines d'un système d'équations (vecteurs de dimension n) :

$$\vec{F}(\vec{x}) = \vec{0} \iff \begin{cases} f_1(x_1, \dots, x_n) = 0 \\ \vdots \\ f_n(x_1, \dots, x_n) = 0 \end{cases}$$

L'approximation linéaire scalaire est remplacée par la matrice **Jacobienne** de $\vec{F}$, notée $J_F(\vec{x})$.

Définition : Itération de Newton Multidimensionnelle

À chaque étape k , l'itération est donnée par :

$$\vec{x}^{k+1} = \vec{x}^k - [J_F(\vec{x}^k)]^{-1} \vec{F}(\vec{x}^k)$$

Dans la pratique numérique, on ne calcule jamais l'inverse de la matrice. On résout le système linéaire suivant pour trouver le pas $\vec{y}$:

$$J_F(\vec{x}^k) \cdot \vec{y} = -\vec{F}(\vec{x}^k)$$

Puis on met à jour le vecteur : $\vec{x}^{k+1} = \vec{x}^k + \vec{y}$.

Théorème

Soit $\vec{F} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ de classe C^2 , et soit $\vec{x}^*$ tel que $\vec{F}(\vec{x}^*) = \vec{0}$.

Si la matrice Jacobienne $J_F(\vec{x}^*)$ est **inversible** (déterminant non nul), alors, pour un point de départ $\vec{x}^0$ suffisamment proche, la méthode converge quadratiquement vers $\vec{x}^*$.

Algorithme / Méthode : Newton pour Systèmes Non Linéaires

```
Données : x_0 (vecteur), tol, max_it, F (fonction vectorielle)
x = x_0
J = J_F(x)           % Évaluation de la Jacobienne initiale
k = 0
inc = tol + 1

Tant que (inc > tol et k < max_it) faire
    % Résolution du système linéaire (ex: x = A\B dans Matlab)
    y = J \ (-F(x))

    % Mise à jour du vecteur
    x_new = x + y

    % Calcul de l'incrément (norme vectorielle)
    inc = ||y||

    x = x_new
    J = J_F(x)           % Réévaluation de la Jacobienne
    k = k + 1
Fin Tant que
```

3 Semaine 3 : Résolution de systèmes linéaires

3.1 Introduction : Résolution de systèmes linéaires

But : Résoudre des systèmes de taille $n \times n$, de la forme :

$$A\vec{x} = \vec{b}$$

où $A = (a_{ij})_{1 \leq i, j \leq n}$ est une matrice carrée, $\vec{x}$ est le vecteur des inconnues et $\vec{b}$ le vecteur second membre.

Exemples d'application :

- Méthode de Newton pour les systèmes non linéaires.
- Résolution d'Équations aux Dérivées Partielles (EDP) discrétisées (cf. suite du cours).

On sait que si A est inversible, le système admet une unique solution.

Question : Comment la trouver efficacement ?

3.2 Systèmes triangulaires

3.2.1 Système triangulaire inférieur

Un système est triangulaire inférieur si $a_{ij} = 0$ pour tout $j > i$.

Algorithme / Méthode : Substitution progressive

Entrées : Matrice $A \in \mathbb{R}^{n \times n}$ triangulaire inférieure, vecteur $\vec{b} \in \mathbb{R}^n$.

Pour $i = 1, \dots, n$ **faire :**

$$x_i = \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j}{a_{ii}}$$

Fin Pour

Retourne : $\vec{x}$, solution de $A\vec{x} = \vec{b}$.

3.2.2 Système triangulaire supérieur

Un système est triangulaire supérieur si $a_{ij} = 0$ pour tout $j < i$.

Algorithme / Méthode : Substitution rétrograde

Entrées : Matrice $A \in \mathbb{R}^{n \times n}$ triangulaire supérieure, vecteur $\vec{b} \in \mathbb{R}^n$.

Pour $i = n$ à 1 **faire :**

$$x_i = \frac{b_i - \sum_{j=i+1}^n a_{ij}x_j}{a_{ii}}$$

Fin Pour

Retourne : $\vec{x}$, solution de $A\vec{x} = \vec{b}$.

3.3 Factorisation LU

3.3.1 Principe et élimination de Gauss

L'objectif est de décomposer la matrice A sous la forme $A = LU$, où L est triangulaire inférieure et U est triangulaire supérieure.

Exemple : Résoudre $A\vec{x} = \vec{b}$

$$A = \begin{pmatrix} 2 & 1 & 0 \\ -4 & 3 & -1 \\ 4 & -3 & 4 \end{pmatrix}, \quad \vec{b} = \begin{pmatrix} 4 \\ 0 \\ -2 \end{pmatrix}$$

Application de l'élimination de Gauss :

1. $L_2 \leftarrow L_2 - \left(\frac{-4}{2}\right) L_1$

2. $L_3 \leftarrow L_3 - \left(\frac{4}{2}\right) L_1$

On obtient une étape intermédiaire. Puis on annule le coefficient de la 3ème ligne, 2ème colonne :

1. $L_3 \leftarrow L_3 - \left(\frac{-5}{5}\right) L_2$

À la fin, on obtient un système triangulaire supérieur $U\vec{x} = \vec{b}^{(3)}$, que l'on résout facilement (substitution rétrograde).

3.3.2 Avantages de la décomposition $L \cdot U = A$

Inconvénient de la méthode de Gauss simple : Si l'on doit résoudre $A\vec{x}^k = \vec{b}^k$ avec de multiples vecteurs $\vec{b}^k$ qui dépendent de k , on doit tout recommencer à chaque fois.

La solution avec LU : Si on définit formellement $L \cdot U = A$, on a maintenant 2 systèmes triangulaires à résoudre à chaque étape k :

$$\begin{cases} L\vec{y}^k = \vec{b}^k & (\text{Système triangulaire inférieur}) \\ U\vec{x}^k = \vec{y}^k & (\text{Système triangulaire supérieur}) \end{cases}$$

Avantages :

1. Calculer **une fois pour toutes** la décomposition LU de A .
2. À chaque étape, on résout très rapidement les deux systèmes $L\vec{y}^k = \vec{b}^k$ et $U\vec{x}^k = \vec{y}^k$.

3.3.3 Pivotage partiel

Exemple problématique :

$$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 7 & 8 & 9 \end{pmatrix} \xrightarrow{L_2 \leftarrow L_2 - 2L_1} \tilde{A}^{(2)} = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 0 & -1 \\ \dots & \dots & \dots \end{pmatrix}$$

Ici, le pivot devient nul ($a_{22} = 0$). L'algorithme bloque. On peut (et on doit) échanger les lignes. Si on fait la même chose pour la matrice L , on obtient la résolution via une matrice de permutation P :

$$\tilde{L}\tilde{U} = PA$$

Résoudre $A\vec{x} = \vec{b}$ devient équivalent à :

$$PA\vec{x} = P\vec{b} \iff \tilde{L}\tilde{U}\vec{x} = P\vec{b}$$

On résout alors : $\tilde{L}\vec{y} = P\vec{b}$ puis $\tilde{U}\vec{x} = \vec{y}$.

En pratique, pour des raisons de stabilité numérique, on va toujours échanger les lignes de sorte à avoir le plus grand pivot possible en valeur absolue.

Algorithme / Méthode : LU avec changement de pivot

Entrées : Matrice A , vecteur $\vec{b}$

Initialisation : $A^{(1)} = A$, $P = I_{n \times n}$, $L = 0_{n \times n}$

Pour $k = 1, \dots, n-1$ **faire :**

- Trouver $i \geq k$ tel que $|a_{ik}^{(k)}|$ soit maximal.
- Échanger les lignes i et k de la matrice $A^{(k)}$, de L , et de P .
- **Pour** $i = k+1, \dots, n$ **faire :**
 - $l_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)}$
 - **Pour** $j = k+1, \dots, n$ **faire :**
 - $a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik} \cdot a_{kj}^{(k)}$

Fin Pour

On complète la diagonale : $l_{ii} = 1$ pour tout i .

U est la partie triangulaire supérieure de $A^{(n)}$.

Résolution :

1. Résoudre $L\vec{y} = P\vec{b}$ (Substitution progressive)
2. Résoudre $U\vec{x} = \vec{y}$ (Substitution rétrograde)

Coût computationnel : $\Theta(n^3)$

3.4 Matrice Symétrique Définie Positive (SDP)

Définition : Matrice SDP

Une matrice $A \in \mathbb{R}^{n \times n}$ est dite Symétrique Définie Positive (SDP) si :

1. Elle est symétrique : $A^T = A$
2. Pour tout vecteur non nul $\vec{x} \in \mathbb{R}^n \setminus \{\vec{0}\}$, on a : $\vec{x}^T A \vec{x} > 0$

Théorème : Factorisation de Cholesky

Soit A une matrice symétrique définie positive. Alors il existe une unique matrice L triangulaire inférieure à valeurs diagonales strictement positives telle que :

$$A = LL^T$$

Si on veut résoudre $A\vec{x} = \vec{b}$ pour une matrice SDP, on calcule sa factorisation de Cholesky, puis on résout en cascade :

$$\begin{cases} L\vec{y} = \vec{b} \\ L^T\vec{x} = \vec{y} \end{cases}$$

3.5 Un exemple d'application : Les moindres carrés

On considère un système surdéterminé d'équations (plus d'équations que d'inconnues) :

$$\begin{cases} a_{11}x_1 + \dots + a_{1n}x_n &= b_1 \\ \vdots & \\ a_{m1}x_1 + \dots + a_{mn}x_n &= b_m \end{cases}$$

Un tel système, noté matriciellement $A\vec{x} = \vec{b}$ avec $A \in \mathbb{R}^{m \times n}$ et $m > n$, n'a généralement **pas de solution exacte**.

Exemple concret : On cherche à déterminer la position $x(t)$ d'un mobile au cours du temps, en supposant que le modèle est affine $x(t) = vt + x_0$. Si l'on effectue 4 mesures à des instants t_i , le système risque fort de ne pas posséder de droite passant exactement par tous les points.

Mais on peut s'intéresser à trouver la "meilleure approximation". On cherche à minimiser l'erreur quadratique, c'est-à-dire trouver $\vec{x}$ qui minimise la norme de l'erreur $\vec{e}$:

$$\min_{\vec{x} \in \mathbb{R}^n} \|\vec{e}\|_2 = \min_{\vec{x} \in \mathbb{R}^n} \|A\vec{x} - \vec{b}\|_2$$

où la norme L_2 est définie par $\|\vec{v}\|_2 = (\sum_i v_i^2)^{\frac{1}{2}}$. On dit qu'on cherche une solution au sens des **moindres carrés**.

Théorème : Équations normales

Soit $A \in \mathbb{R}^{m \times n}$ avec un rang maximal ($\text{rang}(A) = n$, c'est-à-dire que ses colonnes sont linéairement indépendantes ou que A représente une application injective).

Alors il existe un unique vecteur $\vec{x} \in \mathbb{R}^n$ qui minimise la norme $\|A\vec{x} - \vec{b}\|_2$, et ce vecteur est donné par l'unique solution du système carré régulier suivant (appelé équations normales) :

$$A^T A \vec{x} = A^T \vec{b}$$

4 Semaine 4 : Méthodes Itératives et Résolution de Systèmes Linéaires

4.1 Méthodes de Richardson

On aimerait écrire le système $A\mathbf{x} = \mathbf{b}$ sous la forme d'un problème de point fixe. Pour une matrice P inversible, on a l'équivalence :

$$A\mathbf{x} = \mathbf{b} \iff P\mathbf{x} = (P - A)\mathbf{x} + \mathbf{b}$$

On résout $A\mathbf{x} = \mathbf{b}$ en posant $\mathbf{x} = \Phi(\mathbf{x})$ avec :

$$\Phi(\mathbf{x}) = P^{-1}((P - A)\mathbf{x} + \mathbf{b})$$

On peut alors, étant donné $\mathbf{x}_0$, construire les itérations de point fixe :

$$\mathbf{x}_{k+1} = \Phi(\mathbf{x}_k)$$

Si la suite $\{\mathbf{x}_k\}_{k \geq 1}$ converge vers $\mathbf{x}$, alors $\mathbf{x} = \Phi(\mathbf{x})$ et donc $A\mathbf{x} = \mathbf{b}$.

À chaque étape, on a $\mathbf{x}_{k+1} = \Phi(\mathbf{x}_k)$, ce qui s'écrit de manière équivalente :

$$\begin{aligned} P\mathbf{x}_{k+1} &= (P - A)\mathbf{x}_k + \mathbf{b} \\ \implies \underbrace{P(\mathbf{x}_{k+1} - \mathbf{x}_k)}_{\text{Incrément}} &= \underbrace{\mathbf{b} - A\mathbf{x}_k}_{\text{Résidu } \mathbf{r}_k} \end{aligned}$$

Remarque

La matrice P doit être plus simple à inverser que A (sinon la méthode est inutile). On choisit généralement P diagonale ou triangulaire.

Le coût computationnel :

- Calcul du résidu $A\mathbf{x}_k$: Coût en $\mathcal{O}(n^2)$.
- Résolution de $P\mathbf{y} = \mathbf{b} - A\mathbf{x}_k$: Coût en $\mathcal{O}(n)$ si P est diagonale, et en $\mathcal{O}(n^2)$ si P est triangulaire.

Une itération coûte environ l'équivalent d'une itération de descente LU. Il faut que la méthode converge en $k \ll n$ étapes pour qu'elle soit compétitive par rapport aux méthodes directes.

Exemples Classiques

1) Méthode de Jacobi : On choisit $P = \text{diag}(A)$. En formulation coordonnée :

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij} x_j^{(k)} \right]$$

2) Méthode de Gauss-Seidel : On choisit P comme la partie triangulaire inférieure de A , diagonale comprise. En formulation coordonnée :

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right]$$

Analyse de la Convergence

Définition : Norme Matricielle

Pour $A \in \mathbb{R}^{n \times n}$, la norme matricielle subordonnée est définie par :

$$\|A\| = \sup_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} \quad \text{avec} \quad \|\mathbf{x}\| = \left(\sum_{i=1}^n x_i^2 \right)^{1/2}$$

On a alors, $\forall \mathbf{x} \in \mathbb{R}^n$, $\|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\|$.

Définition : Conditionnement et Rayon Spectral

- **Conditionnement** : $\kappa(A) = \|A\| \cdot \|A^{-1}\|$. Si A est Symétrique Définie Positive (SDP), $\kappa(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}$.
- **Rayon spectral** : $\rho(A) = \max |\lambda_i|$ où les λ_i sont les valeurs propres de A .

Théorème

Soit $A \in \mathbb{R}^{n \times n}$. $\lim_{k \rightarrow \infty} A^k = 0 \iff \rho(A) < 1$.

Soit $\{\mathbf{x}_k\}_{k \geq 1}$ la suite issue de l'itération $P\mathbf{x}_{k+1} = (P - A)\mathbf{x}_k + \mathbf{b}$.

Question : Est-ce que $\lim_{k \rightarrow \infty} \mathbf{x}_k = \mathbf{x}$ (où $A\mathbf{x} = \mathbf{b}$) ?

Soit l'erreur $\mathbf{e}_k = \mathbf{x} - \mathbf{x}_k$. En injectant la solution exacte $P\mathbf{x} = (P - A)\mathbf{x} + \mathbf{b}$ et l'itération, on obtient :

$$\begin{aligned} P(\mathbf{x} - \mathbf{x}_{k+1}) &= (P - A)(\mathbf{x} - \mathbf{x}_k) \iff P\mathbf{e}_{k+1} = (P - A)\mathbf{e}_k \\ \implies \mathbf{e}_{k+1} &= P^{-1}(P - A)\mathbf{e}_k \end{aligned}$$

En passant à la norme :

$$\|\mathbf{e}_{k+1}\| \leq \|P^{-1}(P - A)\| \cdot \|\mathbf{e}_k\| \leq \|P^{-1}(P - A)\|^{k+1} \cdot \|\mathbf{e}_0\|$$

Théorème : Convergence de Richardson

1. Si $\|P^{-1}(P - A)\| < 1$, la méthode de Richardson converge $\forall \mathbf{x}_0 \in \mathbb{R}^n$. De plus, la norme donne une idée de la vitesse de convergence.
2. La méthode de Richardson converge si et seulement si $\rho(P^{-1}(P - A)) < 1$.

Critère d'arrêt : On s'arrête lorsque l'erreur relative estimée passe sous une tolérance donnée :

$$\frac{\|\mathbf{x} - \mathbf{x}_k\|}{\|\mathbf{x}\|} \leq \kappa(A) \frac{\|\mathbf{r}_k\|}{\|\mathbf{b}\|} < \text{tol}$$

4.2 Méthodes itératives pour les matrices SDP

Pour toute la suite, on suppose que $A \in \mathbb{R}^{n \times n}$ est Symétrique Définie Positive (SDP).

Pour tout $\mathbf{x} \in \mathbb{R}^n$, on définit la fonctionnelle quadratique :

$$\phi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T A \mathbf{x} - \mathbf{x}^T \mathbf{b}$$

Alors, son gradient est : $\nabla \phi(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$.

Proposition : Lien avec le système linéaire

$$A\mathbf{x} = \mathbf{b} \iff \phi(\mathbf{x}) \leq \phi(\mathbf{y}) \quad \forall \mathbf{y} \in \mathbb{R}^n$$

(i.e. $\mathbf{x}$ minimise globalement ϕ).

Explication / Idée

Puisque A est une matrice symétrique, le gradient de ϕ s'écrit $\nabla \phi(\mathbf{x}) = A\mathbf{x} - \mathbf{b}$. La matrice hessienne correspondante est $\nabla^2 \phi(\mathbf{x}) = A$. Comme A est définie positive, la fonction ϕ est strictement convexe. Par conséquent, ϕ admet un unique minimum global qui correspond à l'unique point critique vérifiant $\nabla \phi(\mathbf{x}) = \mathbf{0}$, ce qui est équivalent à $A\mathbf{x} - \mathbf{b} = \mathbf{0}$, soit $A\mathbf{x} = \mathbf{b}$.

Conséquence : Au lieu de chercher la solution exacte d'un système linéaire, on peut chercher à minimiser la fonction ϕ avec une **méthode de descente**.

Étant donné $\mathbf{x}_0$, on définit la suite :

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{w}_k$$

où $\mathbf{w}_k$ est la direction de descente, et $\alpha_k \in \mathbb{R}$ est le pas, choisi de façon à minimiser $f(\alpha) = \phi(\mathbf{x}_k + \alpha \mathbf{w}_k)$.

Proposition : Pas optimal de descente

Si $f(\alpha) = \phi(\mathbf{x}_k + \alpha \mathbf{w}_k)$ avec $\mathbf{w}_k \neq \mathbf{0}$, le minimum de f est atteint en :

$$\alpha_k = \frac{\mathbf{w}_k^T \mathbf{r}_k}{\mathbf{w}_k^T A \mathbf{w}_k} \quad \text{où } \mathbf{r}_k = \mathbf{b} - A\mathbf{x}_k \text{ (le résidu)}$$

Explication / Idée

Cherchons le point critique de $f(\alpha)$:

$$f'(\alpha) = \frac{d}{d\alpha} \phi(\mathbf{x}_k + \alpha \mathbf{w}_k) = \nabla \phi(\mathbf{x}_k + \alpha \mathbf{w}_k)^T \mathbf{w}_k$$

En injectant l'expression du gradient $\nabla \phi(\mathbf{y}) = A\mathbf{y} - \mathbf{b}$:

$$\begin{aligned} f'(\alpha) &= (A(\mathbf{x}_k + \alpha \mathbf{w}_k) - \mathbf{b})^T \mathbf{w}_k \\ &= (A\mathbf{x}_k - \mathbf{b} + \alpha A\mathbf{w}_k)^T \mathbf{w}_k \\ &= (-\mathbf{r}_k + \alpha A\mathbf{w}_k)^T \mathbf{w}_k \\ &= -\mathbf{r}_k^T \mathbf{w}_k + \alpha \mathbf{w}_k^T A \mathbf{w}_k \end{aligned}$$

En posant $f'(\alpha) = 0$, on trouve bien $\alpha = \frac{\mathbf{r}_k^T \mathbf{w}_k}{\mathbf{w}_k^T A \mathbf{w}_k} = \frac{\mathbf{w}_k^T \mathbf{r}_k}{\mathbf{w}_k^T A \mathbf{w}_k}$.

De plus, la dérivée seconde est $f''(\alpha) = \mathbf{w}_k^T A \mathbf{w}_k > 0$ (car A est SDP et $\mathbf{w}_k \neq \mathbf{0}$), confirmant que ce point est un minimum global le long de la direction $\mathbf{w}_k$.

4.3 Méthode du Gradient (à pas optimal)

Le choix le plus naturel pour la direction de descente est la direction de la plus grande pente (steepest descent) au point $\mathbf{x}_k$, à savoir l'opposé du gradient :

$$\mathbf{w}_k = -\nabla \phi(\mathbf{x}_k) = -(\mathbf{A}\mathbf{x}_k - \mathbf{b}) = \mathbf{b} - \mathbf{A}\mathbf{x}_k = \mathbf{r}_k$$

Si $\mathbf{r}_k = \mathbf{0}$, alors $\mathbf{x}_k$ est solution et on s'arrête. Sinon, on itère avec le pas optimal :

$$\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{r}_k^T \mathbf{A} \mathbf{r}_k}$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{r}_k$$

Pour optimiser les calculs, on met à jour le résidu directement :

$$\mathbf{r}_{k+1} = \mathbf{b} - \mathbf{A}\mathbf{x}_{k+1} = \mathbf{b} - \mathbf{A}(\mathbf{x}_k + \alpha_k \mathbf{r}_k) = \mathbf{r}_k - \alpha_k \mathbf{A} \mathbf{r}_k$$

Algorithm 1 Méthode du Gradient à Pas Optimal

Require: A (SDP), $\mathbf{b}$, $\mathbf{x}_0$, tol , max_it

```

1:  $\mathbf{r} = \mathbf{b} - \mathbf{A}\mathbf{x}_0$ 
2:  $\mathbf{x} = \mathbf{x}_0$ 
3:  $k = 0$ 
4: while  $\|\mathbf{r}\| > \text{tol}$  et  $k < \text{max\_it}$  do
5:    $\mathbf{z} = \mathbf{A}\mathbf{r}$ 
6:    $\alpha = \frac{\mathbf{r}^T \mathbf{r}}{\mathbf{r}^T \mathbf{z}}$ 
7:    $\mathbf{x} = \mathbf{x} + \alpha \mathbf{r}$ 
8:    $\mathbf{r} = \mathbf{r} - \alpha \mathbf{z}$ 
9:    $k = k + 1$ 
10: end while
11: return  $\mathbf{x}$ 

```

Théorème : Convergence de la méthode du Gradient

La méthode du gradient converge pour toute matrice A SDP et $\forall \mathbf{x}_0 \in \mathbb{R}^n$. De plus, on a la majoration d'erreur suivante par rapport à la norme induite par A (où $\|\mathbf{y}\|_A^2 = \mathbf{y}^T \mathbf{A} \mathbf{y}$) :

$$\|\mathbf{x} - \mathbf{x}_k\|_A \leq C \left(\frac{\kappa(A) - 1}{\kappa(A) + 1} \right)^k \|\mathbf{x} - \mathbf{x}_0\|_A$$

Remarque : Si $\kappa(A) \gg 1$, alors la fraction tend vers 1 et la convergence est très lente.

4.4 Méthode du Gradient Conjugué (GC)

Pour pallier le problème de lenteur en zigzag, on introduit une correction. Les directions de descente successives $\mathbf{w}_n$ sont construites de la façon suivante :

$$\mathbf{w}_0 = \mathbf{r}_0$$

$$\mathbf{w}_{n+1} = \mathbf{r}_{n+1} + \beta_n \mathbf{w}_n$$

Le coefficient β_n (facteur de correction) est choisi de manière à exiger l' A -orthogonalité (ou conjugaison) des directions : $\mathbf{w}_{n+1}^T \mathbf{A} \mathbf{w}_i = 0$ pour tout $i \leq n$.

Théorème : Convergence du Gradient Conjugué

Soit $A \in \mathbb{R}^{n \times n}$ SDP. En arithmétique exacte, la méthode du gradient conjugué atteint la solution exacte en au plus n itérations.

De plus, la vitesse de convergence satisfait :

$$\|\mathbf{x} - \mathbf{x}_k\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|\mathbf{x} - \mathbf{x}_0\|_A$$

5 Semaine 5 : Interpolation

Explication / Idée : Idée principale

Construire une fonction continue p telle que $p(x_i) = y_i$ pour $i = 0, \dots, n$.

5.1 Interpolation polynomiale

Étant donnés des points (x_i, y_i) pour $i = 0, \dots, n$, on aimerait construire p , un polynôme de degré n , tel que :

$$p(x_i) = y_i, \quad \forall i = 0, \dots, n$$

Posons $p(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$. La condition $p(x_i) = y_i$ équivaut à :

$$a_0 + a_1x_i + \dots + a_nx_i^n = y_i, \quad \forall i = 0, \dots, n$$

Ce qui nous donne le système matriciel suivant :

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{bmatrix}$$

Où la matrice du système est V , la **matrice de Vandermonde**.

Si les x_i sont tous distincts, il existe un unique polynôme de degré n passant par les points (x_i, y_i) , $i = 0, \dots, n$. Cela implique que le système linéaire est inversible.

Remarque : Problème avec la matrice de Vandermonde

Mais ! Il faut résoudre un système de taille $(n+1) \times (n+1)$, ce qui est **coûteux**.

De plus, le conditionnement de V , noté $\kappa(V)$, est très grand. Par conséquent, une petite erreur sur y entraîne une grande différence sur le résultat.

En effet, si $Va = y$ et $V\tilde{a} = \tilde{y}$, on a :

$$\frac{\|a - \tilde{a}\|}{\|a\|} \leq \kappa(V) \frac{\|y - \tilde{y}\|}{\|y\|}$$

Si $\kappa(V)$ est grand, même si l'erreur relative $\frac{\|y - \tilde{y}\|}{\|y\|} \ll 1$, l'erreur sur les coefficients $\frac{\|a - \tilde{a}\|}{\|a\|}$ sera potentiellement très grande.

5.2 Base de Lagrange

Au lieu de chercher p dans la base canonique $\{1, x, \dots, x^n\}$, on va chercher p dans une base $\{L_i\}_{i=0}^n$.

On aimerait que L_i soit un polynôme de degré n tel que :

$$L_i(x_j) = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{sinon} \end{cases}$$

avec $x_i, i = 0, \dots, n$, les nœuds d'interpolation.

Pourquoi ?

Si l'on écrit $p(x) = \sum_{i=0}^n \alpha_i L_i(x)$, alors :

$$p(x_j) = \sum_{i=0}^n \alpha_i L_i(x_j) = \alpha_j$$

Donc, pour assurer $p(x_j) = y_j$ pour $j = 0, \dots, n$, il suffit de poser :

$$p(x) = \sum_{i=0}^n y_i L_i(x)$$

5.2.1 Construction de la base de Lagrange

Définition : Polynômes de Lagrange

On définit les polynômes de Lagrange $L_i(x)$ par :

$$L_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{(x - x_j)}{(x_i - x_j)}$$

Alors L_i est bien un polynôme de degré n . Il reste à montrer que c'est bien une base de $\mathbb{P}_n$ (l'ensemble des polynômes de degré $\leq n$).

Pour ceci, puisque $\mathbb{P}_n$ est un espace vectoriel de dimension $(n+1)$, et qu'on a $(n+1)$ fonctions L_i , il suffit de montrer que c'est une famille libre.

Explication / Idée : Indépendance linéaire

Supposons qu'il existe des coefficients $c_0, \dots, c_n$ tels que $\sum_{i=0}^n c_i L_i(x) = 0, \forall x$.

En particulier, si on évalue en $x = x_j$:

$$0 = \sum_{i=0}^n c_i L_i(x_j) = c_j$$

Donc $c_j = 0, \forall j$. La famille est donc bien une famille libre.

La famille $\{L_i\}_{i=0}^n$ est appelée la **base de Lagrange** associée aux points $x_i (i = 0, \dots, n)$.

En résumé, pour construire p tel que $p(x_i) = y_i$:

1. On construit la base de Lagrange $\{L_i\}_{i=0}^n$ associée aux points $\{x_i\}_{i=0}^n$.
2. On définit le polynôme interpolant : $p(x) = \sum_{i=0}^n y_i L_i(x)$.

5.3 Interpolation de fonction

Étant donnée une fonction $f : [a, b] \rightarrow \mathbb{R}$ continue, et des points $x_i \in [a, b]$, on aimerait construire p_n , un polynôme de degré n , tel que :

$$p_n(x_i) = f(x_i), \quad \forall i = 0, \dots, n$$

Pourquoi fait-on cela ?

- Évaluation plus rapide de f
- Représentation graphique de f
- Intégration numérique
- Dérivation numérique

Comme vu précédemment, étant donnés les x_i , on pose :

$$p_n(x) = \sum_{i=0}^n f(x_i) L_i(x)$$

qui est l'interpolant de degré n de f aux points x_i ($i = 0, \dots, n$).

Question : Est-ce que p_n est une bonne approximation de f ? Est-ce que $p_n \rightarrow f$ quand $n \rightarrow \infty$?

Théorème : Erreur d'interpolation (nœuds quelconque)

Soit $f : [a, b] \rightarrow \mathbb{R}$ une fonction de classe C^{n+1} . Soient $x_0, \dots, x_n \in [a, b]$.
Soit p_n le polynôme d'interpolation de f aux points x_i . Alors :

$$\max_{x \in [a, b]} |f(x) - p_n(x)| \leq \frac{1}{(n+1)!} \max_{\xi \in [a, b]} |f^{(n+1)}(\xi)| \max_{x \in [a, b]} \prod_{i=0}^n |x - x_i|$$

Théorème : Erreur d'interpolation (nœuds équirépartis)

Soit $f : [a, b] \rightarrow \mathbb{R}$ une fonction de classe C^{n+1} .
Soient $x_0, \dots, x_n \in [a, b]$ équirépartis (i.e., avec un pas $h = \frac{b-a}{n}$). Alors :

$$\max_{x \in [a, b]} |f(x) - p_n(x)| \leq \frac{1}{(n+1)!} \left(\frac{b-a}{n} \right)^{n+1} \max_{\xi \in [a, b]} |f^{(n+1)}(\xi)|$$

Remarque : Instabilités (Phénomène de Runge)

Pour l'interpolation polynomiale globale, quand $n \rightarrow \infty$, il y a des **instabilités**. Il faut que la fonction f soit extrêmement régulière pour que la série d'interpolation converge.

5.4 Interpolation par intervalles (par morceaux / Splines)

Pour contourner le problème des grandes valeurs de n , on considère $(N+1)$ points :

$$a = x_0 < x_1 < \dots < x_N = b$$

On approxime f par morceaux. Sur chaque sous-intervalle $[x_i, x_{i+1}]$ (pour $i = 0, \dots, N-1$), on considère n points équidistribués :

$$x_i = y_{i,0} < y_{i,1} < \dots < y_{i,n} = x_{i+1}$$

On interpole localement par un polynôme de degré n passant par les points $(y_{i,j}, f(y_{i,j}))$.
En faisant cela, on approxime f par une fonction f_h qui est :

- L'interpolant de degré n par intervalles de f .
- Continue sur $[a, b]$.
- Un polynôme de degré n strictement sur chaque sous-intervalle $[x_i, x_{i+1}]$.

Théorème : Erreur d'interpolation par morceaux

Soit $f : [a, b] \rightarrow \mathbb{R}$ une fonction C^{n+1} et f_h son interpolant de degré n par intervalles. Posons $h = \max_i |x_{i+1} - x_i|$. Alors il existe une constante C (indépendante de h) telle que :

$$\max_{x \in [a, b]} |f(x) - f_h(x)| \leq Ch^{n+1}$$

En particulier, si les x_i sont équidistribués avec un pas h , alors cette borne s'applique.

En pratique : on prend n petit ($n = 1, 2, 3, 4$) et N grand (beaucoup de sous-intervalles).

Explication / Idée : Démonstration de la borne d'erreur par morceaux

En utilisant le théorème précédent appliqué localement sur le sous-intervalle $[x_i, x_{i+1}]$, on a :

$$\max_{x \in [x_i, x_{i+1}]} |f(x) - f_h(x)| \leq \frac{1}{(n+1)!} \left(\frac{x_{i+1} - x_i}{n} \right)^{n+1} \max_{\xi \in [x_i, x_{i+1}]} |f^{(n+1)}(\xi)|$$

On majore $x_{i+1} - x_i$ par le pas global h , et le maximum de la dérivée locale par le maximum sur tout le domaine $[a, b]$:

$$\leq \frac{1}{(n+1)! n^{n+1}} \max_{\xi \in [a, b]} |f^{(n+1)}(\xi)| h^{n+1}$$

Ce qui nous donne bien l'estimation globale :

$$\max_{x \in [a, b]} |f(x) - f_h(x)| \leq Ch^{n+1}$$


avec $C = \frac{1}{(n+1)! n^{n+1}} \max_{\xi \in [a, b]} |f^{(n+1)}(\xi)|$.

6 Semaine 6 : Intégration Numérique

But : Calculer une approximation de $\int_a^b f(x)dx$, avec $f : [a, b] \rightarrow \mathbb{R}$ continue.

6.1 Premières formules de quadrature

Idée



1. **On partitionne** $[a, b] : a = x_0 < x_1 < \dots < x_N = b$, avec $x_i = a + ih$ et $h = \frac{b-a}{N}$.
2. $\int_a^b f(x)dx = \sum_{i=0}^{N-1} \int_{x_i}^{x_{i+1}} f(x)dx$
3. **On approxime** $\int_{x_i}^{x_{i+1}} f(x)dx \approx \int_{x_i}^{x_{i+1}} f(x_i)dx = hf(x_i)$
4. **On approxime** $\int_a^b f(x)dx \approx \sum_{i=0}^{N-1} hf(x_i)$

Définition : Formules de quadrature composites

- **Point gauche :** $L_h^{PG}(f) = \sum_{i=0}^{N-1} hf(x_i)$
- **Point droit (on pourrait aussi définir) :** $L_h^{PD}(f) = \sum_{i=0}^{N-1} hf(x_{i+1})$
- **Point milieu :** $L_h^{PM}(f) = \sum_{i=0}^{N-1} hf\left(\frac{x_i+x_{i+1}}{2}\right)$

Questions ?

1. $|\int_a^b f(x)dx - L_h(f)| \rightarrow 0$ quand $h \rightarrow 0$?
2. Est-ce qu'il y a un choix meilleur que les autres ? (PM a l'air meilleur, pourquoi ?)
3. Est-ce qu'on ne pourrait pas approximer par un polynôme de degré n sur chaque sous-intervalle plutôt que par une constante ?

6.2 Formalisme général

On considère $a = x_0 < x_1 < \dots < x_N = b$, $x_i = a + ih$, $h = \frac{b-a}{N}$.

$$\int_a^b f(x)dx = \sum_{i=0}^{N-1} \int_{x_i}^{x_{i+1}} f(x)dx$$

Changement de variable : $x = x_i + \frac{t+1}{2}h \implies dx = \frac{h}{2}dt$, pour $t : -1 \rightarrow 1$.

$$\int_{x_i}^{x_{i+1}} f(x)dx = \frac{h}{2} \int_{-1}^1 f\left(x_i + \frac{t+1}{2}h\right) dt = \frac{h}{2} \int_{-1}^1 g_i(t)dt$$

$$\text{où } g_i(t) := f\left(x_i + \frac{t+1}{2}h\right).$$

On s'est ramené au problème $\int_{-1}^1 g(t)dt$, pour $g : [-1, 1] \rightarrow \mathbb{R}$ continue.

Approximation de $\int_{-1}^1 g(t)dt$:

1. On choisit $(n+1)$ points $t_0, \dots, t_n \in [-1, 1]$ distincts.
2. On choisit la base de Lagrange $l_j(t) = \prod_{k \neq j, k=0}^n \frac{t-t_k}{t_j-t_k}$.
3. On interpole $g(t)$ par le polynôme de degré n : $P_n(t) = \sum_{j=0}^n g(t_j)l_j(t)$.
4. On approxime l'intégrale :

$$\int_{-1}^1 g(t)dt \approx \int_{-1}^1 P_n(t)dt = \int_{-1}^1 \sum_{j=0}^n g(t_j)l_j(t)dt = \sum_{j=0}^n g(t_j) \underbrace{\int_{-1}^1 l_j(t)dt}_{\omega_j \in \mathbb{R}} = \sum_{j=0}^n g(t_j)\omega_j =: J(g)$$

Ici J est une **formule de quadrature à $(n+1)$ points**. Les ω_j sont les **poids** de la formule, et les t_j sont les **points d'intégration**.

Alors :

$$\begin{aligned} \int_a^b f(x)dx &= \sum_{i=0}^{N-1} \frac{h}{2} \int_{-1}^1 g_i(t)dt \approx \sum_{i=0}^{N-1} \frac{h}{2} J(g_i) = \sum_{i=0}^{N-1} \frac{h}{2} \sum_{j=0}^n \omega_j g_i(t_j) \\ &= \sum_{i=0}^{N-1} \frac{h}{2} \sum_{j=0}^n \omega_j f\left(x_i + \frac{t_j+1}{2}h\right) = L_h(f) \end{aligned}$$

6.3 Exemples

Exemple : 1) Formule du Point Gauche

$t_0 = -1$, $l_0(t) = 1$.

$$\omega_0 = \int_{-1}^1 l_0(t)dt = \int_{-1}^1 1dt = 2$$

Donc $J^{PG}(g) = \omega_0 g(t_0) = 2g(-1)$. Et :

$$L_h^{PG}(f) = \sum_{i=0}^{N-1} \frac{h}{2} J^{PG}(g_i) = \sum_{i=0}^{N-1} \frac{h}{2} 2g_i(-1) = \sum_{i=0}^{N-1} h f\left(x_i + \frac{-1+1}{2}h\right) = \sum_{i=0}^{N-1} h f(x_i)$$

Exemple : 2) Formule du Trapèze

$t_0 = -1, t_1 = 1$.

$$l_0(t) = \frac{t - t_1}{t_0 - t_1} = \frac{t - 1}{-2} = \frac{1 - t}{2} \quad l_1(t) = \frac{t - t_0}{t_1 - t_0} = \frac{t + 1}{2}$$

$$\omega_0 = \int_{-1}^1 l_0(t) dt = 1 \quad \omega_1 = \int_{-1}^1 l_1(t) dt = 1$$

$$J^{Trap}(g) = \omega_0 g(t_0) + \omega_1 g(t_1) = 1g(-1) + 1g(1)$$

$$\Rightarrow L_h^{Trap}(f) = \sum_{i=0}^{N-1} \frac{h}{2} J^{Trap}(g_i) = \sum_{i=0}^{N-1} \frac{h}{2} (g_i(-1) + g_i(1)) = \sum_{i=0}^{N-1} \frac{h}{2} (f(x_i) + f(x_{i+1}))$$

Exemple : 3) Formule de Simpson

$t_0 = -1, t_1 = 0, t_2 = 1$.

$$J^S(g) = \frac{1}{3}g(-1) + \frac{4}{3}g(0) + \frac{1}{3}g(1)$$

$$\Rightarrow L_h^S(f) = \sum_{i=0}^{N-1} \frac{h}{2} J^S(g_i) = \sum_{i=0}^{N-1} \frac{h}{2} \left(\frac{1}{3}f(x_i) + \frac{4}{3}f\left(\frac{x_i + x_{i+1}}{2}\right) + \frac{1}{3}f(x_{i+1}) \right)$$

6.4 Estimation d'erreur

Définition : Exactitude

Une formule de quadrature J est **exacte à l'ordre n** si $J(p) = \int_{-1}^1 p(t) dt \quad \forall p \in \mathbb{P}_n$.

Proposition

Soit $J(g) = \sum_{j=0}^n \omega_j g(t_j)$ (t_j distincts).

La formule de quadrature est exacte à l'ordre n ssi $\omega_j = \int_{-1}^1 l_j(t) dt$ (l_j base de Lagrange).

Démonstration. $\Rightarrow$ Supposons J exacte à l'ordre n . Alors $J(l_j) = \int_{-1}^1 l_j(t) dt$. Mais $J(l_j) = \sum_{k=0}^n \omega_k l_j(t_k) = \omega_j \Rightarrow \omega_j = \int_{-1}^1 l_j(t) dt$.

$\Leftarrow$ Supposons $\omega_j = \int_{-1}^1 l_j(t) dt$. Soit $p \in \mathbb{P}_n : p(t) = \sum_{j=0}^n p(t_j) l_j(t)$. Alors $\int_{-1}^1 p(t) dt = \int_{-1}^1 \sum_{j=0}^n p(t_j) l_j(t) dt = \sum_{j=0}^n p(t_j) \int_{-1}^1 l_j(t) dt = \sum_{j=0}^n p(t_j) \omega_j = J(p)$. $\square$

Proposition

Soit J une formule de quadrature exacte à l'ordre n . Soit L_h la formule composite correspondante pour approximer $\int_a^b f(x)dx$ ($L_h = \sum_{i=0}^{N-1} \frac{h}{2} J(g_i)$).

Supposons f $(n+1)$ fois continûment dérivable sur $[a, b]$. Alors $\exists C > 0$ indépendant de h (ici C dépend de f) tel que :

$$\left| \int_a^b f(x)dx - L_h(f) \right| \leq Ch^{n+1}$$

Exemple d'applications (vérification de l'exactitude) :

1. **Point gauche** : $J^{PG}(g) = 2g(-1)$.

J^{PG} est exacte à l'ordre 0 car $\omega_0 = \int_{-1}^1 1dt = 2$.

J^{PG} n'est pas exacte à l'ordre 1 car $\int_{-1}^1 tdt = 0$ et $J^{PG}(t) = 2 \times (-1) = -2 \neq 0$.

$$\Rightarrow \left| \int_a^b f(x)dx - L_h^{PG}(f) \right| \leq Ch^1$$

2. **Point milieu** : $J^{PM}(g) = 2g(0)$.

J^{PM} est exacte à l'ordre 1 car $\omega_0 = \int_{-1}^1 1dt = 2$ et $J^{PM}(t) = 2 \times 0 = 0 = \int_{-1}^1 tdt$.

Mais elle n'est pas exacte pour l'ordre 2 car $J^{PM}(t^2) = 2 \times 0^2 = 0 \neq \int_{-1}^1 t^2 dt = \frac{2}{3}$.

$$\Rightarrow \left| \int_a^b f(x)dx - L_h^{PM}(f) \right| \leq Ch^2$$

3. **Formule du trapèze** exacte à l'ordre 1 $\Rightarrow$ erreur $\leq Ch^2$

4. **Formule de Simpson** est exacte à l'ordre 3 $\Rightarrow$ erreur $\leq Ch^4$

Explication / Idée : Culture générale : Quadratures de Gauss

Question ? Choix des points d'intégration ?

Si on choisit $t_0, \dots, t_n$ les $(n+1)$ zéros distincts dans $[-1, 1]$ (appelés **points de Gauss**) du polynôme de Legendre $L_{n+1}(t)$, alors la formule de quadrature :

$$J^{Gauss}(g) = \sum_{j=0}^n \omega_j g(t_j) \quad \text{avec } \omega_j = \int_{-1}^1 l_j(t)dt$$

est exacte à l'ordre $2n+1$.

7 Semaine 7 : Dérivation Numérique

7.1 Introduction à la dérivation numérique

But : Approximer $f'(x_0)$ en n'utilisant que des évaluations ponctuelles de f .

Pourquoi ?

- Expression analytique de f' difficile à calculer.
- Expression analytique de f inconnue (f donnée par un algorithme, une "boîte noire").
- **Idée :** Approximation numérique d'équations différentielles.

Par définition :


$$f'(x_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h} = \lim_{h \rightarrow 0} \frac{f(x_0) - f(x_0 - h)}{h} = \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0 - h)}{2h}$$

Donc pour h assez petit, une bonne approximation de $f'(x_0)$ devrait être :

Définition : Formules de différences finies

- $\partial_h^+ f(x_0) := \frac{f(x_0+h) - f(x_0)}{h}$ (formule de différences finies progressives)
- $\partial_h^- f(x_0) := \frac{f(x_0) - f(x_0-h)}{h}$ (formule de différences finies rétrogrades)
- $\partial_h^c f(x_0) := \frac{f(x_0+h) - f(x_0-h)}{2h}$ (formule de différences finies centrées)

Illustration



Questions :

1. $|f'(x_0) - \partial_h^{+/-} f(x_0)| \rightarrow 0$ quand $h \rightarrow 0$?

2. Est-ce qu'une des formules est meilleure ?

On observe que $|f'(x_0) - \partial_h^{+/-} f(x_0)| \leq Ch$ et $|f'(x_0) - \partial_h^c f(x_0)| \leq Ch^2$.

7.2 Convergence d'une formule de différences finies : exemples

Proposition : (1) Preuve pour la formule progressive

Montrer que si $x_0 \in \mathbb{R}$ et $f \in \mathcal{C}^2([x_0, x_0 + h_0])$ pour un $h_0 > 0$, alors :

$$|f'(x_0) - \partial_h^+ f(x_0)| \leq Ch$$

avec $C > 0$ indépendante de h , $\forall h \leq h_0$.

Preuve : On a par le développement de Taylor :

$$f(x_0 + h) = f(x_0) + f'(x_0)h + \frac{f''(\zeta)h^2}{2}, \quad \zeta \in [x_0, x_0 + h]$$

Donc :

$$\frac{f(x_0 + h) - f(x_0)}{h} = f'(x_0) + \frac{f''(\zeta)h}{2}$$

Ainsi :

$$\left| \frac{f(x_0 + h) - f(x_0)}{h} - f'(x_0) \right| = \frac{|f''(\zeta)|}{2}h \leq \left(\max_{\zeta \in [x_0, x_0 + h_0]} \frac{|f''(\zeta)|}{2} \right) h$$

Proposition : (2) Preuve pour la formule centrée

Montrer que si $x_0 \in \mathbb{R}$ et $f \in \mathcal{C}^3([x_0 - h_0, x_0 + h_0])$ pour un $h_0 > 0$, alors :

$$|f'(x_0) - \partial_h^c f(x_0)| \leq Ch^2$$

avec $C > 0$ indépendante de h , $\forall h \leq h_0$.

Preuve :

$$f(x_0 + h) = f(x_0) + f'(x_0)h + \frac{f''(x_0)h^2}{2} + \frac{f'''(\zeta)h^3}{6}$$

$$f(x_0 - h) = f(x_0) - f'(x_0)h + \frac{f''(x_0)h^2}{2} - \frac{f'''(\eta)h^3}{6}$$

Donc :

$$f(x_0 + h) - f(x_0 - h) = 2hf'(x_0) + \frac{f'''(\zeta)h^3}{6} + \frac{f'''(\eta)h^3}{6}$$

Ainsi, $\forall h \leq h_0$:

$$\left| \frac{f(x_0 + h) - f(x_0 - h)}{2h} - f'(x_0) \right| \leq \max_{\zeta \in [x_0 - h_0, x_0 + h_0]} |f'''(\zeta)| \frac{h^2}{6} \times 2$$

L'erreur est bien bornée par Ch^2 .

7.3 Formules plus générales

Définition

Une formule de différences finies qui utilise $m + n + 1$ points $x_0 + ih, i = -m, \dots, 0, \dots, n$ s'écrit :

$$D_h f(x) = \frac{1}{h} \sum_{i=-m}^n \alpha_i f(x_0 + ih)$$

avec α_i indépendants de h .

Exemple : La formule de différences finies centrées correspond à $m = n = 1$ avec $\alpha_{-1} = -\frac{1}{2}$, $\alpha_0 = 0$ et $\alpha_1 = \frac{1}{2}$:

$$\partial_h^c f(x_0) = \frac{1}{h} \left(-\frac{1}{2} f(x_0 - h) \right) + \frac{1}{h} \left(\frac{1}{2} f(x_0 + h) \right) = \frac{f(x_0 + h) - f(x_0 - h)}{2h}$$

Question : Étant donnés les points $x_0 + ih, i = -m, \dots, n$, comment choisir les α_i ?

- **Possibilité 1 :** (1) Construire P , le polynôme interpolant de degré $(m + n)$ aux points $x_0 + ih$. (2) Calculer $P'(x)$. (3) Définir $D_h f(x) := P'(x_0)$.
- **Possibilité 2 (Méthode des coeff. indéterminés) :** On choisit les α_i de sorte à avoir le plus grand ordre possible, i.e., de sorte à annuler le plus de termes possibles dans les développements de Taylor.

Exemple : Construction avec les développements de Taylor

$$D_h f(x_0) = \frac{1}{h} \sum_{i=-1}^1 \alpha_i f(x_0 + ih) = \frac{\alpha_{-1}}{h} f(x_0 - h) + \frac{\alpha_0}{h} f(x_0) + \frac{\alpha_1}{h} f(x_0 + h)$$

On peut le ré-écrire avec les développements de Taylor :

$$\begin{aligned} D_h f(x_0) &= \frac{\alpha_{-1}}{h} \left[f(x_0) - f'(x_0)h + f''(x_0)\frac{h^2}{2} - f'''(\zeta)\frac{h^3}{6} \right] \\ &\quad + \frac{\alpha_0}{h} f(x_0) \\ &\quad + \frac{\alpha_1}{h} \left[f(x_0) + f'(x_0)h + f''(x_0)\frac{h^2}{2} + f'''(\eta)\frac{h^3}{6} \right] \end{aligned}$$

En regroupant les termes :

$$\begin{aligned} D_h f(x_0) &= \frac{1}{h} f(x_0)(\alpha_{-1} + \alpha_0 + \alpha_1) \\ &\quad + f'(x_0)(-\alpha_{-1} + \alpha_1) \\ &\quad + \frac{h}{2}(\alpha_{-1} + \alpha_1)f''(x_0) \\ &\quad + \frac{h^2}{6}(-\alpha_{-1}f'''(\zeta) + \alpha_1f'''(\eta)) \end{aligned}$$

Pour approximer $f'(x_0)$, on doit avoir :

$$\begin{cases} \alpha_{-1} + \alpha_0 + \alpha_1 = 0 \\ -\alpha_{-1} + \alpha_1 = 1 \end{cases}$$

Pour avoir le plus grand ordre possible, on demande d'annuler le terme d'ordre suivant :

$$\alpha_{-1} + \alpha_1 = 0$$

Le système complet donne :

$$\begin{cases} \alpha_{-1} = -\frac{1}{2} \\ \alpha_0 = 0 \\ \alpha_1 = \frac{1}{2} \end{cases}$$

On retrouve donc la formule de différences finies centrées.

7.4 Dérivées d'ordre supérieur

On peut utiliser les mêmes méthodes pour construire une formule $D_h^l f(x_0) = \frac{1}{h^l} \sum_{i=-m}^n \alpha_i f(x_0 + ih)$ qui approxime $f^{(l)}(x_0)$.

Exemple : On aimerait construire $D_h^2 f(x) = \frac{1}{h^2}(\alpha_{-1}f(x_0 - h) + \alpha_0f(x_0) + \alpha_1f(x_0 + h))$ pour approximer $f''(x_0)$. On écrit :

$$f(x_0 + h) = f(x_0) + f'(x_0)h + f''(x_0)\frac{h^2}{2} + f'''(x_0)\frac{h^3}{6} + f^{IV}(\zeta)\frac{h^4}{24}$$

$$f(x_0 - h) = f(x_0) - f'(x_0)h + f''(x_0)\frac{h^2}{2} - f'''(x_0)\frac{h^3}{6} + f^{IV}(\eta)\frac{h^4}{24}$$

Donc :

$$\begin{aligned} D_h^2 f(x_0) &= \frac{1}{h^2} f(x_0)(\alpha_{-1} + \alpha_0 + \alpha_1) \\ &+ \frac{1}{h} f'(x_0)(-\alpha_{-1} + \alpha_1) \\ &+ \frac{1}{2} f''(x_0)(\alpha_{-1} + \alpha_1) \\ &+ h f'''(x_0) \left(\frac{-\alpha_{-1} + \alpha_1}{6} \right) \\ &+ \frac{h^2}{24} (\alpha_{-1} f^{IV}(\zeta) + \alpha_1 f^{IV}(\eta)) \end{aligned}$$

On doit donc avoir :

$$\begin{cases} \alpha_{-1} + \alpha_0 + \alpha_1 = 0 \\ -\alpha_{-1} + \alpha_1 = 0 \\ \frac{\alpha_{-1} + \alpha_1}{2} = 1 \implies \alpha_{-1} + \alpha_1 = 2 \end{cases}$$

Et donc :

$$\begin{cases} \alpha_{-1} = 1 \\ \alpha_0 = -2 \\ \alpha_1 = 1 \end{cases} \quad (\text{Note : corrigé par rapport au manuscrit brut})$$

Finalement :

$$D_h^2 f(x) = \frac{f(x_0 + h) - 2f(x_0) + f(x_0 - h)}{h^2}$$

En faisant cette construction, on a montré que $|f''(x_0) - D_h^2 f(x_0)| \leq Ch^2, \forall h \leq h_0$ si f était régulière (C^4).

7.5 Dérivées numériques et erreurs d'arrondis

Pourquoi est-ce que $|f'(x_0) - \partial_h f(x_0)|$ ré-augmente pour h (très) petit ? **Erreur d'arrondis :** L'ordinateur n'évalue pas exactement f , mais une approximation $\hat{f}(x) = f(x)(1 + \eta)$, avec $\eta \approx 10^{-16}$.

Donc, ce que l'ordinateur calcule est :

$$\begin{aligned} \hat{\partial}_h^+ f(x_0) &= \frac{\hat{f}(x_0 + h) - \hat{f}(x_0)}{h} = \frac{f(x_0 + h)(1 + \eta_1) - f(x_0)(1 + \eta_2)}{h} \quad (\eta_1, \eta_2 \approx 10^{-16}) \\ &= \left(\frac{f(x_0 + h) - f(x_0)}{h} \right) + \frac{\eta_1}{h} f(x_0 + h) - \frac{\eta_2}{h} f(x_0) \\ &= \left(f'(x_0) + \frac{f''(\zeta)}{2} h \right) + \frac{\eta_1}{h} f(x_0 + h) - \frac{\eta_2}{h} f(x_0) \end{aligned}$$

Donc :

$$|f'(x_0) - \hat{\partial}_h^+ f(x_0)| \leq \max |f''(\zeta)| \frac{h}{2} + 2 \max |f(x)| \frac{10^{-16}}{h}$$

L'erreur $\Sigma(h)$ se comporte donc comme :

Remarque : Erreur totale

$$\Sigma(h) \approx C_1 h + \frac{C_2 10^{-16}}{h}$$

Une unique minimum en :

$$h_{opt} = \sqrt{\frac{C_2 10^{-16}}{C_1}} \approx 10^{-8}$$

8 Semaine 8 : Équations Différentielles Ordinaires (1er ordre)

8.1 Introduction et Problème de Cauchy

On considère des problèmes d'évolution temporelle de la forme suivante :

Définition : Problème de Cauchy

Trouver une fonction $u : \mathbb{R}_+ \rightarrow \mathbb{R}$ solution du problème de Cauchy :

$$\begin{cases} \frac{du}{dt}(t) = f(t, u(t)), & \text{pour } t > 0 \\ u(0) = u_0 & \text{(Condition initiale)} \end{cases} \quad (*)$$

où $f : \mathbb{R}_+ \times \mathbb{R} \rightarrow \mathbb{R}$ est une fonction donnée et $u_0 \in \mathbb{R}$ est une valeur initiale connue.

Exemples physiques et biologiques

Exemple : 1. Équation de Newton en 1D

D'après la seconde loi de Newton ($F = ma$), on cherche la vitesse $v(t)$ au temps $t \geq 0$ d'une particule (en supposant la masse $m = 1$ pour simplifier) :

$$\begin{cases} \frac{dv}{dt}(t) = F(t, v(t)) \\ v(0) = v_0 \end{cases}$$

Ici, la solution s'écrit sous forme intégrale : $v(t) = v_0 + \int_0^t F(s, v(s)) ds$.

Exemple : 2. Évolution d'une population

Soit $u(t)$ le nombre d'individus dans une population au temps t . Supposons un taux de croissance proportionnel à la population avec une constante $k > 0$.

$$\begin{cases} \frac{du(t)}{dt} = k u(t) \\ u(0) = u_0 \end{cases}$$

La solution exacte est donnée par la loi exponentielle : $u(t) = u_0 e^{kt}$.

8.2 Existence et Unicité : Exemples et Contre-exemples

Face au problème (*), deux questions fondamentales se posent :

1. Est-ce que le problème (*) admet toujours une solution ?

2. Est-ce que cette solution est unique ?

Exemple : Exemples et pathologiques

1) Solution unique et globale :

$$\begin{cases} \frac{du}{dt} = 3u(t) - 3t \\ u(0) = 0 \end{cases} \implies u(t) = -\frac{1}{3}e^{3t} + t + \frac{1}{3}$$

Cette solution est unique et parfaitement définie pour tout $t > 0$.

2) Perte d'unicité :

$$\begin{cases} \frac{du}{dt} = \sqrt[3]{u(t)}, & t > 0 \\ u(0) = 0 \end{cases}$$

Ce système admet plusieurs solutions distinctes : $u_1(t) = 0$, $u_2(t) = \sqrt{\frac{8t^3}{27}}$ et $u_3(t) = -\sqrt{\frac{8t^3}{27}}$.

3) Explosion en temps fini :

$$\begin{cases} \frac{du}{dt} = u^2(t), & t > 0 \\ u(0) = 1 \end{cases} \implies u(t) = \frac{1}{1-t}$$

La solution est unique mais elle "explose" au temps $t = 1$. Elle n'est pas définie globalement sur $\mathbb{R}_+$.

Théorème : Théorème de Cauchy-Lipschitz

Soit $f : \mathbb{R}_+ \times \mathbb{R} \rightarrow \mathbb{R}$ continue par rapport à ses deux variables. On suppose de plus qu'elle est globalement lipschitzienne par rapport à sa deuxième variable, c'est-à-dire qu'il existe une constante $L \in \mathbb{R}^+$ telle que :

$$|f(t, x) - f(t, y)| \leq L|x - y|, \quad \forall t \in \mathbb{R}_+, \forall x, y \in \mathbb{R}$$

Alors il existe une **unique** solution $u(t)$ au problème (*). Elle est définie pour tout $t \geq 0$ (existence globale) et est continûment dérivable.

Explication / Idée : Analyse des contre-exemples

La condition de Lipschitz est la clé !

- Dans le cas 2) ($f(t, u) = \sqrt[3]{u}$), la dérivée par rapport à u tend vers l'infini en 0. La fonction n'est pas lipschitzienne en 0, ce qui cause la **perte d'unicité**.
- Dans le cas 3) ($f(t, u) = u^2$), la dérivée par rapport à u est $2u$, qui n'est pas bornée sur $\mathbb{R}$. La fonction n'est pas globalement lipschitzienne, ce qui explique pourquoi la solution **explose en temps fini** et n'existe pas globalement pour tout $t \geq 0$.

8.3 Méthodes Numériques d'Approximation

Pour résoudre ces problèmes sur un ordinateur, on discrétise l'intervalle d'étude $t \in [0, T]$ en N sous-intervalles. Soit le pas de temps $\Delta t = \frac{T}{N}$. Les temps discrets sont $t_n = n\Delta t$ pour $n = 0, \dots, N$.

On cherche des approximations $u^n \approx u(t_n)$.

8.3.1 Approche par Dérivation Numérique (Différences Finies)

Algorithme / Méthode : 1. Schéma d'Euler Progressif (Explicite)

On approche la dérivée au temps t_n par la différence finie progressive :

$$\frac{du(t_n)}{dt} = f(t_n, u(t_n)) \approx \frac{u^{n+1} - u^n}{\Delta t}$$

Ceci amener au schéma direct à calculer :

$$\begin{cases} u^{n+1} = u^n + \Delta t f(t_n, u^n) \\ u^0 = u_0 \end{cases}$$

Algorithme / Méthode : 2. Schéma d'Euler Rétrograde (Implicite)

On écrit l'équation au temps futur t_{n+1} et on utilise une différence finie rétrograde :

$$\frac{du(t_{n+1})}{dt} = f(t_{n+1}, u(t_{n+1})) \approx \frac{u^{n+1} - u^n}{\Delta t}$$

Le terme suivant u^{n+1} dépend de lui-même :

$$\begin{cases} u^{n+1} - u^n - \Delta t f(t_{n+1}, u^{n+1}) = 0 \\ u^0 = u_0 \end{cases}$$

Explication / Idée : Résolution du schéma implicite

À chaque étape du schéma rétrograde, l'inconnue est u^{n+1} . On doit donc résoudre une équation de la forme $g(X) = 0$ avec $g(X) = X - u^n - \Delta t f(t_{n+1}, X)$.

On utilise typiquement la **méthode de Newton** pour trouver la racine. On l'initialise avec la valeur u^n (qui est une très bonne approximation de u^{n+1} si Δt est petit), ce qui garantit généralement une convergence très rapide.

8.3.2 Approche par Intégration Numérique

On intègre formellement l'EDO entre t_n et t_{n+1} :

$$u(t_{n+1}) - u(t_n) = \int_{t_n}^{t_{n+1}} f(s, u(s)) ds$$

Selon la méthode de quadrature (calcul d'aire) choisie, on retrouve différents schémas :

- **Point Gauche** (Rectangle gauche) : $\int_{t_n}^{t_{n+1}} f \approx \Delta t f(t_n, u(t_n)) \implies$ **Euler Explicite**.
- **Point Droit** (Rectangle droit) : $\int_{t_n}^{t_{n+1}} f \approx \Delta t f(t_{n+1}, u(t_{n+1})) \implies$ **Euler Implicite**.

Algorithme / Méthode : 3. Crank-Nicolson

En approchant l'intégrale par la **méthode des trapèzes**, on obtient :

$$u(t_{n+1}) - u(t_n) \approx \frac{\Delta t}{2} (f(t_n, u(t_n)) + f(t_{n+1}, u(t_{n+1})))$$

C'est un schéma **implicite** réputée pour sa meilleure stabilité (A-stabilité) :

$$u^{n+1} = u^n + \frac{\Delta t}{2} (f(t_n, u^n) + f(t_{n+1}, u^{n+1}))$$

Algorithme / Méthode : 4. Méthode de Heun (Prédicteur-Correcteur RK2)

Pour se débarrasser du caractère implicite de Crank-Nicolson, on remplace le u^{n+1} inconnu par une *prédiction* obtenue via un pas d'Euler explicite : $u_{\text{pred}}^{n+1} = u^n + \Delta t f(t_n, u^n)$.

$$\begin{cases} K_1 = f(t_n, u^n) \\ K_2 = f(t_{n+1}, u^n + \Delta t K_1) \\ u^{n+1} = u^n + \frac{\Delta t}{2} (K_1 + K_2) \end{cases}$$

C'est un schéma purement **explicite** (Runge-Kutta d'ordre 2).

Algorithme / Méthode : 5. Méthode de Runge-Kutta 4 (RK4)

On utilise la formule de **Simpson** pour obtenir un schéma explicite de très haute précision (ordre 4) :

$$\int_{t_n}^{t_{n+1}} f(s, u(s)) ds \approx \frac{\Delta t}{6} (f(t_n) + 4f(t_{n+\frac{1}{2}}) + f(t_{n+1}))$$

En évaluant intelligemment les pentes intermédiaires, on construit :

$$\begin{cases} K_1 = f(t_n, u^n) \\ K_2 = f\left(t_n + \frac{\Delta t}{2}, u^n + \frac{\Delta t}{2} K_1\right) \\ K_3 = f\left(t_n + \frac{\Delta t}{2}, u^n + \frac{\Delta t}{2} K_2\right) \\ K_4 = f(t_{n+1}, u^n + \Delta t K_3) \\ u^{n+1} = u^n + \frac{\Delta t}{6} (K_1 + 2K_2 + 2K_3 + K_4) \end{cases}$$

Explication / Idée : Lien entre Simpson et RK4

La formule de Simpson classique accorde les poids $(1, 4, 1)/6$ aux points (gauche, milieu, droit). Dans le schéma RK4, les pentes au point milieu sont échantillonnées deux fois (K_2 et K_3), d'où les poids respectifs $\frac{1}{6}$, $\frac{2}{6}$, $\frac{2}{6}$, et $\frac{1}{6}$ qui, additionnés, respectent la pondération globale de l'intégration parabolique de Simpson.

9 Semaine 9 : EDOs scalaires et Systèmes

9.1 Méthodes à 1 pas et Erreur

Rappel : On considère le problème continu

$$\begin{cases} \frac{du}{dt}(t) = f(t, u(t)), & t \in (0, T] \\ u(0) = u_0 \end{cases} \quad (1)$$

On partitionne l'intervalle de temps $[0, T]$. Soit $\Delta t = \frac{T}{N}$. On définit les instants discrets :

$$0 = t_0 < t_1 < \dots < t_n = t_0 + n\Delta t < \dots < t_N = T$$

Définition : Méthode à 1 pas

Une méthode à 1 pas pour approximer la solution de (1) est de la forme :

$$\frac{u_{n+1} - u_n}{\Delta t} = \Phi_f(u_n, u_{n+1}, t_n, \Delta t) \quad (2)$$

Explication / Idée

Dans le cas d'une méthode explicite, la fonction d'incrément Φ_f ne dépend pas de u_{n+1} .

Algorithme / Méthode : Fonctions d'incrément classiques

Méthode	Φ_f
EP (Euler Progressif)	$f(t_n, u_n)$
ER (Euler Rétrograde)	$f(t_{n+1}, u_{n+1})$
CN (Crank-Nicolson)	$\frac{1}{2}(f(t_n, u_n) + f(t_{n+1}, u_{n+1}))$
Heun	$\frac{1}{2}(f(t_n, u_n) + f(t_{n+1}, u_n + \Delta t f(t_n, u_n)))$
RK4	$\frac{1}{6}(k_1 + 2k_2 + 2k_3 + k_4)$

Définition : Erreur de troncature locale

L'erreur de troncature locale au temps t_{n+1} est définie par :

$$\tau_{n+1} = \frac{u(t_{n+1}) - u(t_n)}{\Delta t} - \Phi_f(u(t_n), u(t_{n+1}), t_n, \Delta t) \quad (3)$$

Théorème : Consistance et Convergence

Si f est lipschitzienne par rapport à son second argument et si la méthode est consistante à l'ordre p ($\tau(T) = \mathcal{O}(\Delta t^p)$), alors elle est convergente à l'ordre p ($e(T) = \mathcal{O}(\Delta t^p)$).

Exemple : Euler Progressif

Pour EP, par développement de Taylor :

$$\tau_{n+1} \leq \frac{\Delta t}{2} \max_{t \in [0, T]} |u''(t)|$$

La méthode est donc consistante et convergente à l'ordre 1.

9.2 Stabilité

Explication / Idée : Choix des méthodes implicites

Considérons $\frac{du}{dt} = -\lambda u$ avec $\lambda > 0$.

- **EP** : $u_{n+1} = (1 - \lambda \Delta t) u_n$. Stable ssi $\Delta t < \frac{2}{\lambda}$ (Conditionnelle).
- **ER** : $u_{n+1} = \frac{1}{1 + \lambda \Delta t} u_n$. Stable $\forall \Delta t > 0$ (Inconditionnelle).

9.3 Systèmes d'EDOs

Pour $\vec{u}(t) \in \mathbb{R}^k$, on utilise les mêmes schémas sous forme vectorielle. La stabilité pour $\frac{d\vec{u}}{dt} = -A\vec{u}$ dépend des valeurs propres λ_i de A . EP est stable si $|1 - \Delta t \lambda_i| < 1$ pour toutes les valeurs propres.

9.4 EDOs d'ordre supérieur

Algorithme / Méthode : Réduction à l'ordre 1

On transforme $\frac{d^2 u}{dt^2} = f(t, u, u')$ en un système d'ordre 1 en posant $v = u'$:

$$\frac{d}{dt} \begin{pmatrix} u \\ v \end{pmatrix} = \begin{pmatrix} v \\ f(t, u, v) \end{pmatrix}$$

10 Semaine 10 :

Problèmes aux limites unidimensionnels (Semaine 10)

Il s'agit de trouver $u(x)$ tel que :

$$\begin{cases} -u''(x) = f(x) & \text{pour } 0 < x < L \\ u(0) = \alpha \\ u(L) = \beta \end{cases}$$

Ces conditions aux bords sont appelées **Conditions de Dirichlet**.

Exemple : Déplacement vertical d'une corde

Un exemple classique modélisant l'équation ci-dessus est le déplacement d'une corde de longueur L fixée à ses extrémités (dans ce cas typique, $\alpha = 0$).

Théorème : Existence de la solution

Si f est continue sur $[0, L]$, alors le problème aux limites admet une solution unique.

Remarque

Bien qu'une solution existe, il n'y a généralement pas de formule analytique pour la trouver explicitement. On cherche donc à l'approximer numériquement.

10.1 Méthode des différences finies

On pose un maillage régulier de l'intervalle $[0, L]$:

$$0 = x_0 < x_1 < \dots < x_{N+1} = L$$

avec un pas constant $h = \frac{L}{N+1}$, soit $x_j = j \frac{L}{N+1}$ pour $j = 0, \dots, N+1$.

On cherche à construire des approximations u_j de la solution exacte $u(x_j)$ aux points du maillage pour $j = 0, \dots, N+1$.

On se rappelle, par développement de Taylor, que :

$$u''(x) = \frac{u(x+h) - 2u(x) + u(x-h)}{h^2} + \mathcal{O}(h^2)$$

On considère le schéma numérique suivant en discrétisant l'opérateur continu :

$$\frac{-u_{j+1} + 2u_j - u_{j-1}}{h^2} = f(x_j), \quad \text{pour } j = 1, \dots, N$$

Avec les conditions aux limites imposées :

$$u_0 = \alpha \quad \text{et} \quad u_{N+1} = \beta$$

Évaluons le schéma aux bornes du domaine :

- **Pour** $j = 1$: le schéma s'écrit $\frac{-u_2 + 2u_1 - u_0}{h^2} = f(x_1)$. En injectant $u_0 = \alpha$, on obtient :

$$\frac{-u_2 + 2u_1}{h^2} = f(x_1) + \frac{\alpha}{h^2}$$

- **Pour** $j = N$: le schéma s'écrit $\frac{-u_{N+1} + 2u_N - u_{N-1}}{h^2} = f(x_N)$. En injectant $u_{N+1} = \beta$, on obtient :

$$\frac{2u_N - u_{N-1}}{h^2} = f(x_N) + \frac{\beta}{h^2}$$

Ce schéma numérique peut s'écrire sous forme matricielle $A\vec{u} = \vec{f}$:

$$\frac{1}{h^2} \begin{pmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & -1 & 2 & -1 \\ 0 & \cdots & 0 & -1 & 2 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_{N-1} \\ u_N \end{pmatrix} = \begin{pmatrix} f(x_1) + \frac{\alpha}{h^2} \\ f(x_2) \\ \vdots \\ f(x_{N-1}) \\ f(x_N) + \frac{\beta}{h^2} \end{pmatrix}$$

Remarque

La matrice A est tridiagonale (avec des 2 sur la diagonale principale, et des -1 sur les diagonales supérieure et inférieure). Elle est **Symétrique Définie Positive (SDP)**. On peut donc résoudre le système efficacement à l'aide d'une **factorisation de Cholesky**.

10.2 Erreur numérique

On s'intéresse à la norme infinie de l'erreur, définie par :

$$e := \max_{j=1,\dots,N} |u(x_j) - u_j|$$

Théorème : Principe du maximum discret

Si $A\vec{u} = \vec{f}$, alors :

$$\max_{j=1,\dots,N} |u_j| \leq \frac{L^2}{8} \max_{j=1,\dots,N} |f(x_j)| + \max(|\alpha|, |\beta|)$$

Définition : Erreur de troncature locale

Soit u la solution exacte du problème. L'erreur de troncature locale τ_j en un point x_j évalue à quel point la solution exacte satisfait le schéma numérique. On la définit par :

$$\frac{-u(x_{j+1}) + 2u(x_j) - u(x_{j-1}))}{h^2} = f(x_j) + \tau_j, \quad j = 1, \dots, N$$

En soustrayant l'équation du schéma numérique de celle de l'erreur de troncature locale, on obtient l'équation régissant l'erreur globale $e_j = u(x_j) - u_j$:

$$\frac{-e_{j+1} + 2e_j - e_{j-1}}{h^2} = \tau_j, \quad \text{pour } j = 1, \dots, N$$

Avec $e_0 = 0$ et $e_{N+1} = 0$.

Ceci s'écrit sous la forme vectorielle $A\vec{e} = \vec{\tau}$, où $\vec{e} = (e_1, e_2, \dots, e_N)^T$ et $\vec{\tau} = (\tau_1, \tau_2, \dots, \tau_N)^T$.

Par le théorème précédent (principe du maximum), on déduit directement une borne de stabilité :

$$\max_{j=1, \dots, N} |e_j| \leq \frac{L^2}{8} \max_{j=1, \dots, N} |\tau_j|$$

D'autre part, on sait par le développement de Taylor que l'erreur de troncature est bornée par :

$$|\tau_j| = \left| \frac{-u(x_{j+1}) + 2u(x_j) - u(x_{j-1}))}{h^2} + u''(x_j) \right| \leq \frac{h^2}{12} \max_{x \in [0, L]} |u^{(4)}(x)|$$

si $u \in C^4([0, L])$.

On a donc montré le théorème fondamental suivant :

Théorème : Convergence du schéma

Si $u \in C^4([0, L])$ est la solution exacte du problème et si $\vec{u}$ est la solution exacte du système linéaire $A\vec{u} = \vec{f}$, alors l'erreur globale satisfait :

$$\max_{j=1, \dots, N} |u(x_j) - u_j| \leq Ch^2$$

avec la constante $C = \frac{L^2}{96} \max_{x \in [0, L]} |u^{(4)}(x)|$.

10.3 Conditions aux limites de Neumann

Considérons maintenant un problème avec une condition de dérivée au bord (Condition de Neumann) :

$$\begin{cases} -u''(x) = f(x) & 0 < x < L \\ u(0) = \alpha \\ u'(L) = \beta \end{cases} \quad (\text{Condition de Neumann})$$

Question : Que faire de la condition limite $u'(L) = \beta$?

Algorithme / Méthode : Méthode du point fantôme

On va rajouter une inconnue fictive au-delà du domaine, au point $x_{N+2} = L + h$. L'approximation centrée de la dérivée en $x_{N+1} = L$ s'écrit :

$$u'(L) \approx \frac{u_{N+2} - u_N}{2h} = \beta \implies u_{N+2} = 2h\beta + u_N$$

Le schéma général reste valide pour les nœuds intérieurs :

$$\frac{-u_{j+1} + 2u_j - u_{j-1}}{h^2} = f(x_j), \quad j = 1, \dots, N$$

Et on évalue ce même schéma au bord $j = N + 1$:

$$\frac{-u_{N+2} + 2u_{N+1} - u_N}{h^2} = f(x_{N+1})$$

En substituant u_{N+2} par son expression tirée de la condition de Neumann, on obtient :

$$\frac{-(2h\beta + u_N) + 2u_{N+1} - u_N}{h^2} = f(x_{N+1}) \implies \frac{2u_{N+1} - 2u_N}{h^2} = f(x_{N+1}) + \frac{2\beta}{h}$$

En divisant par 2, l'équation s'écrit :

$$\frac{u_{N+1} - u_N}{h^2} = \frac{1}{2}f(x_{N+1}) + \frac{\beta}{h}$$

On peut réécrire le schéma sous forme matricielle modifiée, de taille $(N+1) \times (N+1)$:

$$\frac{1}{h^2} \begin{pmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \ddots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & \ddots & -1 & 2 & -1 \\ 0 & \cdots & 0 & -1 & 1 \end{pmatrix} \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_N \\ u_{N+1} \end{pmatrix} = \begin{pmatrix} f(x_1) + \frac{\alpha}{h^2} \\ f(x_2) \\ \vdots \\ f(x_N) \\ \frac{1}{2}f(x_{N+1}) + \frac{\beta}{h} \end{pmatrix}$$

La matrice $\tilde{A}$ reste Symétrique Définie Positive (SDP), on peut donc résoudre ce système linéaire avec la méthode de Cholesky. L'ordre d'approximation reste quadratique :

$$e := \max_{j=1,\dots,N+1} |u(x_j) - u_j| \leq Ch^2.$$

10.4 Ajout d'un terme linéaire de réaction

Considérons l'équation avec un terme supplémentaire :

$$\begin{cases} -u''(x) + c(x)u(x) = f(x) & 0 < x < L \\ u(0) = \alpha \\ u(L) = \beta \end{cases}$$

On suppose que $c(x) \geq 0$ pour tout $x \in [0, L]$.

On procède comme précédemment et on considère le schéma :

$$\begin{cases} \frac{-u_{j+1} + 2u_j - u_{j-1}}{h^2} + c(x_j)u_j = f(x_j) & \text{pour } j = 1, \dots, N \\ u_0 = \alpha \\ u_{N+1} = \beta \end{cases}$$

On peut écrire ce système sous la forme $(A + D)\vec{u} = \vec{f}$, où la matrice A et le vecteur $\vec{f}$ sont identiques au problème classique de Dirichlet, et D est la matrice diagonale évaluée aux points du maillage :

$$D = \begin{pmatrix} c(x_1) & 0 & \cdots & 0 \\ 0 & c(x_2) & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & c(x_N) \end{pmatrix}$$

Puisque $c(x) \geq 0 \forall x \in [0, L]$, la matrice diagonale D est semi-définie positive. Comme A est SDP, la somme $A + D$ est également Symétrique Définie Positive $\implies$ Résolution par Cholesky.

10.5 Ajout d'un terme non-linéaire

Considérons enfin une équation avec une non-linéarité :

$$\begin{cases} -u''(x) + c(x, u(x)) = f(x) & 0 < x < L \\ u(0) = \alpha \\ u(L) = \beta \end{cases}$$

On suppose que la dérivée partielle vérifie $\frac{\partial c}{\partial u} \geq 0$.

Le schéma numérique prend la forme non-linéaire :

$$\frac{-u_{j+1} + 2u_j - u_{j-1}}{h^2} + c(x_j, u_j) = f(x_j), \quad \text{avec } u_0 = \alpha \text{ et } u_{N+1} = \beta$$

Ce qui donne le système de résidus suivant $\vec{F}(\vec{u}) = \vec{0}$:

$$\begin{cases} \frac{2u_1 - u_2}{h^2} + c(x_1, u_1) - f(x_1) - \frac{\alpha}{h^2} = 0 \\ \frac{-u_1 + 2u_2 - u_3}{h^2} + c(x_2, u_2) - f(x_2) = 0 \\ \vdots \\ \frac{-u_{N-1} + 2u_N}{h^2} + c(x_N, u_N) - f(x_N) - \frac{\beta}{h^2} = 0 \end{cases}$$

Algorithme / Méthode : Méthode de Newton

Pour résoudre le système non-linéaire $\vec{F}(\vec{u}) = \vec{0}$, on utilise la méthode de Newton-Raphson vectorielle. Étant donné une itération courante $\vec{u}^k$, on calcule la mise à jour $\vec{u}^{k+1}$ satisfaisant le système linéaire :

$$DF(\vec{u}^k)(\vec{u}^{k+1} - \vec{u}^k) = -\vec{F}(\vec{u}^k)$$

En particulier, il faut calculer et inverser la matrice Jacobienne $DF(\vec{u})$. On trouve :

$$DF(\vec{u}) = \frac{1}{h^2} \begin{pmatrix} 2 & -1 & 0 & \cdots \\ -1 & 2 & -1 & \cdots \\ 0 & -1 & 2 & \ddots \\ \vdots & \vdots & \ddots & \ddots \end{pmatrix} + \begin{pmatrix} \frac{\partial c}{\partial u}(x_1, u_1) & 0 & \cdots & 0 \\ 0 & \frac{\partial c}{\partial u}(x_2, u_2) & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \frac{\partial c}{\partial u}(x_N, u_N) \end{pmatrix}$$

Si la jacobienne $DF(\vec{u}^k)$ est inversible (ce qui est garanti car A est SDP et la diagonale est non-négative), on peut itérer la méthode de Newton jusqu'à ce que le critère d'arrêt soit satisfait, par exemple :

$$\|\vec{u}^{k+1} - \vec{u}^k\| < \text{tolérance (ex. } 10^{-7})$$

Une fois le critère d'arrêt satisfait, la solution est donnée par $\vec{u} \approx \vec{u}^{k+1}$.

11 Équation de la chaleur-Semaine 11


Définition : Le problème de la chaleur 1D

Trouver $T : [0, L] \times \mathbb{R}_+ \rightarrow \mathbb{R}$ telle que :

$$\rho c_p \frac{\partial T}{\partial t}(x, t) - k \frac{\partial^2 T}{\partial x^2}(x, t) = f(x, t), \quad 0 < x < L, t > 0 \quad (4)$$

$$T(0, t) = T(L, t) = 0 \quad (\text{Conditions aux limites}) \quad (5)$$

$$T(x, 0) = w(x), \quad 0 < x < L \quad (\text{Condition initiale}) \quad (6)$$



Explication / Idée : Données du problème

- $T(x, t)$: Température au point x et au temps t .
- $w(x)$: Température initiale connue.
- $\rho > 0$: Densité.
- $c_p > 0$: Chaleur spécifique.
- $k > 0$: Conductivité thermique.
- f : Source de chaleur (Puissance par unité de longueur).

On cherche la température $T(x, t)$ pour $x \in [0, L]$ et $t > 0$.

Remarque : Principe de conservation

L'équation de la chaleur traduit le principe de conservation de l'énergie thermique. Si on intègre l'équation par rapport à x entre 0 et L , on obtient :

$$\underbrace{\int_0^L \rho c_p \frac{\partial T}{\partial t}(x, t) dx}_{\text{Variation de l'énergie thermique}} - \underbrace{\int_0^L k \frac{\partial^2 T}{\partial x^2}(x, t) dx}_{\text{Flux de chaleur}} = \underbrace{\int_0^L f(x, t) dx}_{\text{Puissance thermique}}$$

Ce qui se réécrit :

$$\frac{d}{dt} \int_0^L \rho c_p T(x, t) dx - \left[k \frac{\partial T}{\partial x}(x, t) \right]_{x=0}^L = \int_0^L f(x, t) dx$$

11.1 Problème modèle

Quitte à diviser toute l'équation par ρc_p , on peut se ramener à considérer l'équation normalisée suivante (en redéfinissant $k \leftarrow k/(\rho c_p)$ et $f \leftarrow f/(\rho c_p)$) :

$$\begin{cases} \frac{\partial u}{\partial t}(x, t) - k \frac{\partial^2 u}{\partial x^2}(x, t) = f(x, t), & 0 < x < L, t > 0 \\ u(0, t) = u(L, t) = 0, & t > 0 \\ u(x, 0) = w(x), & 0 < x < L \end{cases} \quad (7)$$

Exemple : Solution exacte analytique


Si $f(x, t) = 0$ et la condition initiale est $w(x) = \sin\left(\frac{\pi x}{L}\right)$, alors la solution exacte est donnée par :

$$u(x, t) = \sin\left(\frac{\pi x}{L}\right) \exp\left(-\frac{k\pi^2}{L^2}t\right)$$

Proposition : Principe du maximum continu

Supposons $f(x, t) = 0$ et soit u la solution de l'équation homogène. Alors :

1. Si $w(x) \geq 0$, alors $u(x, t) \geq 0$ pour tout $t \geq 0$.
2. $\max_{x \in [0, L]} u(x, t) \leq \max_{x \in [0, L]} w(x)$.




11.2 Approximation numérique

On cherche à approximer la solution u de l'EDP pour $(x, t) \in [0, L] \times [0, T]$. Pour cela, on discrétise le domaine spatio-temporel.

Discrétisation en espace : $0 = x_0 < x_1 < \dots < x_{N+1} = L$, avec un pas $h = \frac{L}{N+1}$ tel que $x_i = i \cdot h$.

Discrétisation en temps : $0 = t_0 < t_1 < \dots < t_M = T$, avec un pas $\tau = \frac{T}{M}$ tel que $t_n = n \cdot \tau$.



On cherche à trouver des approximations $u_i^n \approx u(x_i, t_n)$ avec l'indice n pour le temps et l'indice i pour l'espace, pour $i = 1, \dots, N$ et $n = 1, \dots, M$.

Initialisation : On connaît la condition initiale $u(x_i, t_0) = u(x_i, 0) = w(x_i)$ pour $i = 1, \dots, N$. On pose donc : $u_i^0 = w(x_i)$.

Question : Comment calculer u_i^{n+1} si on connaît les valeurs au pas de temps précédent u_i^n ?

11.2.1 Schéma d'Euler progressif (explicite)

On fixe n et on réécrit l'équation de la chaleur évaluée au point (x_i, t_n) :

$$\frac{\partial u}{\partial t}(x_i, t_n) - k \frac{\partial^2 u}{\partial x^2}(x_i, t_n) = f(x_i, t_n)$$

On approche les dérivées par différences finies (progressives en temps, centrées en espace) :

$$\underbrace{\frac{u(x_i, t_{n+1}) - u(x_i, t_n)}{\tau}}_{\text{Différences finies progressives}} - k \underbrace{\frac{u(x_{i+1}, t_n) - 2u(x_i, t_n) + u(x_{i-1}, t_n))}{h^2}}_{\text{Différences finies centrées}} = f(x_i, t_n) + \mathcal{O}(\tau + h^2)$$


En remplaçant la solution exacte $u(x_i, t_n)$ par notre approximation numérique u_i^n et en tronquant l'erreur $\mathcal{O}(\tau + h^2)$, on obtient le schéma explicite suivant :

Algorithme / Méthode : Méthode à un pas en temps (Euler Explicite)

$$\begin{cases} \frac{u_i^{n+1} - u_i^n}{\tau} - k \frac{u_{i+1}^n - 2u_i^n + u_{i-1}^n}{h^2} = f(x_i, t_n) \\ u_0^n = u_{N+1}^n = 0 \quad (\text{Conditions aux limites}) \end{cases} \quad (8)$$

En isolant u_i^{n+1} , la relation de récurrence devient :

$$u_i^{n+1} = \left(1 - \frac{2k\tau}{h^2}\right) u_i^n + \frac{k\tau}{h^2} (u_{i+1}^n + u_{i-1}^n) + \tau f(x_i, t_n)$$



Sous forme matricielle, en posant $U^n = (u_1^n, \dots, u_N^n)^T$ et $F(t_n) = (f(x_1, t_n), \dots, f(x_N, t_n))^T$, le schéma s'écrit :

$$U^{n+1} = (I - \tau A)U^n + \tau F(t_n)$$

où A est la matrice tridiagonale :

$$A = \frac{k}{h^2} \begin{pmatrix} 2 & -1 & & 0 \\ -1 & \ddots & \ddots & \\ & \ddots & 2 & -1 \\ 0 & & -1 & 2 \end{pmatrix} \in \mathbb{R}^{N \times N}$$

11.2.2 Schéma d'Euler rétrograde (implicite)

On fixe n et on écrit cette fois l'équation au point (x_i, t_{n+1}) :

$$\frac{\partial u}{\partial t}(x_i, t_{n+1}) - k \frac{\partial^2 u}{\partial x^2}(x_i, t_{n+1}) = f(x_i, t_{n+1})$$

En appliquant des différences finies rétrogrades pour le temps et centrées pour l'espace, nous obtenons :

$$\frac{u(x_i, t_{n+1}) - u(x_i, t_n)}{\tau} - k \frac{u(x_{i+1}, t_{n+1}) - 2u(x_i, t_{n+1}) + u(x_{i-1}, t_{n+1}))}{h^2} = f(x_i, t_{n+1}) + \mathcal{O}(\tau + h^2)$$

Algorithme / Méthode : Méthode d'Euler Implicite

On considère donc le schéma numérique suivant :

$$\begin{cases} \frac{u_i^{n+1} - u_i^n}{\tau} - k \frac{u_{i+1}^{n+1} - 2u_i^{n+1} + u_{i-1}^{n+1}}{h^2} = f(x_i, t_{n+1}) \\ u_0^{n+1} = u_{N+1}^{n+1} = 0 \end{cases} \quad (9)$$

En réarrangeant les termes pour isoler les inconnues au temps t_{n+1} :

$$\left(1 + \frac{2k\tau}{h^2}\right) u_i^{n+1} - \frac{k\tau}{h^2} (u_{i+1}^{n+1} + u_{i-1}^{n+1}) = u_i^n + \tau f(x_i, t_{n+1})$$

Sous forme matricielle, le système devient :

$$(I + \tau A)U^{n+1} = U^n + \tau F(t_{n+1})$$

À chaque itération, il faut résoudre un système linéaire pour trouver le vecteur U^{n+1} !

11.3 Stabilité

Dans ce qui suit, on suppose qu'il n'y a pas de terme source ($f = 0$).

Définition : Critères de Stabilité

Un schéma numérique qui approxime la solution de l'équation de la chaleur est stable si :

1. **Principe du maximum discret (positivité)** : $\forall i = 1, \dots, N, u_i^n \geq 0 \implies \forall i = 1, \dots, N, u_i^{n+1} \geq 0$.
2. **Non-croissance de la norme infini** : $\max_{i=1, \dots, N} |u_i^{n+1}| \leq \max_{i=1, \dots, N} |u_i^n|$.

On aimerait en effet que l'approximation numérique reproduise le comportement physique de la solution exacte continue.

Théorème : Stabilité des schémas d'Euler

- On peut montrer que le **schéma d'Euler rétrograde (implicite) est inconditionnellement stable** (stable quels que soient les choix de h et τ).
- Le **schéma d'Euler progressif (explicite) est stable sous condition CFL** : il est stable si et seulement si

$$\tau \leq \frac{h^2}{2k}$$

11.4 Convergence

On s'intéresse à l'erreur d'approximation à l'instant final $T = t_M$:

$$e := \max_{i=1, \dots, N} |u(x_i, T) - u_i^M|$$

Pour les deux méthodes (Euler progressif / rétrograde), on a utilisé :

- 1 formule d'ordre 1 en temps : $\mathcal{O}(\tau)$.
- 1 formule d'ordre 2 en espace : $\mathcal{O}(h^2)$.

Proposition : Ordre des schémas

On peut montrer que les deux schémas vus dans ce cours sont d'ordre $\mathcal{O}(\tau + h^2)$.

Autrement dit : si on divise le pas d'espace h par 2 et le pas de temps τ par 4, l'erreur globale est divisée par 4.

12 Semaine 12-Transport et Ondes

12.1 Équation de transport

On s'intéresse à l'équation aux dérivées partielles (EDP) de transport linéaire du premier ordre pour $0 < x < L$ et $t > 0$:

$$\frac{\partial u}{\partial t}(x, t) + c_0 \frac{\partial u}{\partial x}(x, t) = f(x, t) \quad (10)$$

Soumise à la condition initiale :

$$u(x, 0) = w(x), \quad x \in [0, L]$$

Et à une condition aux limites (si $c_0 > 0$) :

$$u(0, t) = g(t), \quad t > 0$$

Cette équation modélise par exemple le transport d'un polluant le long d'une rivière, dans un tronçon de longueur L , avec une vitesse de courant $c_0 > 0$.

Exemple : Solution exacte pour une source nulle

Si $f = 0$, $g = 0$ et $w(x)$ est la source du polluant (telle que $w(0) = 0$), alors la solution de l'équation (10) est donnée par :

$$u(x, t) = w(x - c_0 t) \quad \text{pour } x - c_0 t \geq 0$$

La solution $u(x, t)$ est simplement la condition initiale qui est **transportée de gauche à droite** dans le sens du courant à la vitesse c_0 .

Et si $c_0 < 0$?

Le courant va dans l'autre sens, de la droite vers la gauche. La caractéristique de l'équation vient donc de $x = L$ et s'écoule vers $x = 0$. Il faut par conséquent imposer une condition limite en $x = L$ au lieu de $x = 0$.

Le problème devient :

$$\begin{cases} \frac{\partial u}{\partial t}(x, t) + c_0 \frac{\partial u}{\partial x}(x, t) = f(x, t) & \text{pour } x \in (0, L), t > 0 \\ u(x, 0) = w(x) & \text{pour } x \in [0, L] \\ u(L, t) = g(t) & \text{pour } t > 0 \end{cases} \quad (11)$$

Si $f = 0$, $g = 0$ et $w(L) = 0$, alors $u(x, t) = w(x - c_0 t)$. Puisque $c_0 < 0$, la condition initiale est translatée de **droite à gauche**.

12.1.1 Approximation numérique

On discrétise le domaine spatial et temporel :

- **Espace** : $x_j = jh$ pour $j = 0, \dots, N + 1$, avec le pas $h = \frac{L}{N+1}$.

- **Temps** : $0 = t_0 < t_1 < \dots < t_M = T$, avec le pas temporel $\tau = \frac{T}{M}$ (soit $t_n = n\tau$, $n = 0, \dots, M$).

On cherche à approcher les valeurs de la fonction continue aux nœuds de ce maillage. On pose :

$$u_j^n \approx u(x_j, t_n)$$

Connaissant la condition initiale $u_j^0 = w(x_j)$ pour $j = 0, \dots, N+1$, on se pose la question : connaissant u_j^n (à l'instant t_n), comment calculer u_j^{n+1} (à l'instant t_{n+1}) ?

On écrit l'EDP au temps t_n et au point spatial x_j :

$$\frac{\partial u}{\partial t}(x_j, t_n) + c_0 \frac{\partial u}{\partial x}(x_j, t_n) = f(x_j, t_n) \quad (12)$$

On approche la dérivée temporelle par une différence finie progressive (Euler explicite) :

$$\frac{\partial u}{\partial t}(x_j, t_n) \approx \frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{\tau}$$

Question : Quelle formule de différences finies utiliser pour approximer $\frac{\partial u}{\partial x}$?

12.1.2 Schéma décentré amont (Upwind)

On utilise un schéma dit *décentré amont* (ou "Upwind"). Ce schéma respecte la direction de propagation de l'information (les caractéristiques) :

- L'information est transportée de **gauche à droite** si $c_0 > 0$. On regarde "en arrière" (à gauche).
- L'information est transportée de **droite à gauche** si $c_0 < 0$. On regarde "en avant" (à droite).

Explication / Idée : Rigidité du choix décentré (Upwind)

En analyse numérique, utiliser un schéma centré pour le terme de convection (de type $\frac{u_{j+1}^n - u_{j-1}^n}{2h}$) avec un schéma d'Euler explicite en temps engendre une instabilité inconditionnelle (toute perturbation, même minime, explosera exponentiellement, indépendamment des pas τ et h). Le schéma décentré amont introduit une "viscosité numérique" artificielle qui stabilise le calcul, tant que la condition de Courant-Friedrichs-Lewy (CFL) est respectée.

Cas $c_0 > 0$:

On utilise une différence finie rétrograde en espace :

$$\frac{\partial u}{\partial x}(x_j, t_n) \approx \frac{u(x_j, t_n) - u(x_{j-1}, t_n)}{h}$$

Le schéma devient pour $j = 1, \dots, N+1$:

$$\frac{u_j^{n+1} - u_j^n}{\tau} + c_0 \frac{u_j^n - u_{j-1}^n}{h} = f(x_j, t_n)$$

Soit, de manière explicite :

Algorithme / Méthode : Schéma décentré pour $c_0 > 0$

$$u_j^{n+1} = u_j^n - \tau c_0 \frac{u_j^n - u_{j-1}^n}{h} + \tau f(x_j, t_n), \quad \forall j = 1, \dots, N+1$$

$$u_0^n = g(t_n) \quad (\text{condition au bord entrant})$$

Cas $c_0 < 0$:

On utilise une différence finie progressive en espace :

$$\frac{\partial u}{\partial x}(x_j, t_n) \approx \frac{u(x_{j+1}, t_n) - u(x_j, t_n)}{h}$$

Le schéma devient pour $j = 0, \dots, N$:

$$\frac{u_j^{n+1} - u_j^n}{\tau} + c_0 \frac{u_{j+1}^n - u_j^n}{h} = f(x_j, t_n)$$

Soit, de manière explicite :

Algorithme / Méthode : Schéma décentré pour $c_0 < 0$

$$u_j^{n+1} = u_j^n - \tau c_0 \frac{u_{j+1}^n - u_j^n}{h} + \tau f(x_j, t_n), \quad \forall j = 0, \dots, N$$

$$u_{N+1}^n = g(t_n) \quad (\text{condition au bord entrant})$$

12.1.3 Stabilité

Considérons le cas homogène : $f = 0$ et $g = 0$. La solution exacte du problème de transport continu est $u(x, t) = w(x - c_0 t)$. Cette solution exacte possède deux propriétés fondamentales :

1. **Positivité** : Si la donnée initiale $w(x) \geq 0$, alors $u(x, t) \geq 0$ pour tout $x \in [0, L]$ et $t \geq 0$.
2. **Principe du maximum** : $\max_x |u(x, t)| \leq \max_x |w(x)|$. L'amplitude de la solution ne croît pas dans le temps.

On définit un schéma numérique comme étant **stable** s'il reproduit numériquement ces propriétés :

1. Si $u_j^0 \geq 0$ pour $j = 0, \dots, N+1$, alors $u_j^{n+1} \geq 0$ pour tout n .
2. $\max_{j=0, \dots, N+1} |u_j^{n+1}| \leq \max_{j=0, \dots, N+1} |u_j^n|$

Proposition

Le schéma décentré amont est stable sous la condition :

$$0 < \tau \leq \frac{h}{|c_0|}$$

Il s'agit de la célèbre condition de **Courant-Friedrichs-Lewy (CFL)**.*Preuve à faire en exercice.*

Explication / Idée : Interprétation physique de la CFL

La condition $\tau \leq \frac{h}{|c_0|}$ s'écrit aussi $|c_0|\tau \leq h$. Physiquement, la distance parcourue par l'onde ou la particule (à vitesse c_0) durant un pas de temps τ ne doit pas dépasser la taille d'une maille spatiale h . Si l'information "saute" plusieurs mailles en une seule itération, le schéma numérique à 3 points (qui ne regarde que la maille directement voisine) ne peut pas capter correctement la physique, ce qui mène à une explosion des valeurs (instabilité). Mathématiquement, cela implique que le domaine de dépendance numérique contient strictement le domaine de dépendance continu de l'EDP.

Remarque : Ordre d'erreur du schéma

Définissons l'erreur globale maximale :

$$e := \max_{j=0, \dots, N+1} |u(x_j, T) - u_j^M|$$

Comme on a utilisé des formules de différences finies d'ordre 1 (aussi bien en espace, décentré, qu'en temps, progressif), l'erreur de troncature se comporte asymptotiquement comme :

$$e = \mathcal{O}(h + \tau)$$

Ce schéma est donc consistant d'ordre 1.

12.2 Équation des ondes

On considère l'équation des ondes (hyperbolique du second ordre) :

$$\frac{\partial^2 u}{\partial t^2}(x, t) - c^2 \frac{\partial^2 u}{\partial x^2}(x, t) = f(x, t), \quad 0 < x < L, \quad t > 0 \quad (13)$$

avec $c > 0$ la vitesse de l'onde.

Le système requiert **deux conditions initiales** (car c'est une dérivée seconde en temps) :

$$\begin{aligned} u(x, 0) &= w(x), \quad 0 < x < L \quad (\text{déplacement initial}) \\ \frac{\partial u}{\partial t}(x, 0) &= v(x), \quad 0 < x < L \quad (\text{vitesse initiale}) \end{aligned}$$

Et des **conditions aux limites** (par exemple de Dirichlet, cordes fixées) :

$$u(0, t) = u(L, t) = 0, \quad t > 0$$

Cette équation modélise par exemple la déformation d'une corde élastique de longueur L fixée à ses 2 extrémités et soumise à une force $f(x, t)$.

Exemple : Formule de d'Alembert et Réflexions

Si la force est nulle ($f = 0$), la vitesse initiale nulle ($v = 0$) et les conditions au bord respectées par la condition initiale ($w(0) = w(L) = 0$), on peut définir $\tilde{w}$ comme le prolongement de w en une fonction

impaire et $2L$ -périodique.

Alors, la solution s'écrit selon la formule de d'Alembert :

$$u(x, t) = \frac{1}{2} (\tilde{w}(x - ct) + \tilde{w}(x + ct))$$

Ce comportement représente deux ondes, qui sont transportées de gauche à droite et inversement, et qui **se réfléchissent** contre les bords $x = 0$ et $x = L$.

Par exemple, si $w(x) = \sin\left(\frac{\pi x}{L}\right)$:

$$u(x, t) = \frac{1}{2} \left[\sin\left(\frac{\pi(x - ct)}{L}\right) + \sin\left(\frac{\pi(x + ct)}{L}\right) \right] = \sin\left(\frac{\pi x}{L}\right) \cos\left(\frac{\pi ct}{L}\right)$$

Ceci représente une onde stationnaire (oscillation pure dans le temps modulant la condition initiale).

12.2.1 Schéma numérique (Différences finies centrées)

On procède à la même discrétisation que précédemment : $x_j = jh$ et $t_n = n\tau$, avec $j = 1, \dots, N$. On cherche à calculer les approximations $u_j^n \approx u(x_j, t_n)$.

Pour le problème des ondes, on utilise des formules de différences finies **centrées** à la fois pour $\frac{\partial^2}{\partial t^2}$ et pour $\frac{\partial^2}{\partial x^2}$. L'équation s'écrit donc numériquement :

$$\frac{u_j^{n+1} - 2u_j^n + u_j^{n-1}}{\tau^2} - c^2 \frac{u_{j+1}^n - 2u_j^n + u_{j-1}^n}{h^2} = f(x_j, t_n)$$

Avec les conditions aux limites appliquées directement :

$$u_0^n = 0 \quad \text{et} \quad u_{N+1}^n = 0 \quad \forall n$$

En réarrangeant pour exprimer le pas de temps futur, on obtient un schéma explicite à 3 niveaux de temps (souvent appelé schéma *leapfrog* ou saute-mouton) :

$$u_j^{n+1} = 2u_j^n - u_j^{n-1} + \left(\frac{c\tau}{h}\right)^2 (u_{j+1}^n - 2u_j^n + u_{j-1}^n) + \tau^2 f(x_j, t_n) \quad (14)$$

Avec cette récurrence, on peut calculer u_j^{n+1} **connaissant** u_j^n **et** u_j^{n-1} .

Cependant, à l'initialisation du problème, nous connaissons :

- $u_j^0 = w(x_j)$ (Position initiale)
- $u_0^0 = u_{N+1}^0 = 0$

Question : Comment calculer la première itération u_j^1 (au temps t_1) vu qu'il nous manque u_j^{-1} ?

12.2.2 Traitement de la vitesse initiale (Point fictif)

Au temps $t_0 = 0$ (soit $n = 0$), si l'on écrit naïvement le schéma (14), on fait intervenir un point temporel fictif $t_{-1} = -\tau$:

$$\frac{u_j^1 - 2u_j^0 + u_j^{-1}}{\tau^2} - c^2 \frac{u_{j+1}^0 - 2u_j^0 + u_{j-1}^0}{h^2} = f(x_j, 0)$$

Pour remplacer u_j^{-1} dans ce schéma, on utilise la condition initiale sur la dérivée, $\frac{\partial u}{\partial t}(x_j, 0) = v(x_j)$. Pour maintenir une précision d'ordre $\mathcal{O}(\tau^2)$, on discrétise cette vitesse initiale par une **différence finie centrée** :

$$\frac{\partial u}{\partial t}(x_j, 0) \approx \frac{u(x_j, t_1) - u(x_j, t_{-1})}{2\tau}$$

On considère dans ce schéma que $\frac{u_j^1 - u_j^{-1}}{2\tau} = v(x_j)$, ce qui nous donne l'expression du point fictif :

$$u_j^{-1} = u_j^1 - 2\tau v(x_j)$$

On substitue cette relation dans notre schéma pour $n = 0$:

$$\frac{u_j^1 - 2u_j^0 + (u_j^1 - 2\tau v(x_j))}{\tau^2} - c^2 \frac{u_{j+1}^0 - 2u_j^0 + u_{j-1}^0}{h^2} = f(x_j, 0)$$

Ce qui se simplifie en groupant les termes en u_j^1 :

Algorithme / Méthode : Initialisation du schéma de l'équation des ondes

Pour calculer le premier pas u_j^1 (pour $j = 1, \dots, N$) avec une précision $\mathcal{O}(\tau^2 + h^2)$:

$$u_j^1 = u_j^0 + \tau v(x_j) + \frac{1}{2} \left(\frac{c\tau}{h} \right)^2 (u_{j+1}^0 - 2u_j^0 + u_{j-1}^0) + \frac{\tau^2}{2} f(x_j, 0)$$

Avec les conditions aux limites $u_0^1 = u_{N+1}^1 = 0$.

Avec ceci, on peut calculer u_j^1 pour $j = 1, \dots, N$. Étant donnés u_j^0 et u_j^1 , la récurrence explicite standard (14) permet de calculer la solution à tous les temps t_n .

12.2.3 Stabilité et Erreur (Équation des ondes)

Remarque : Condition de Stabilité

Pour le schéma explicite de l'équation des ondes, on peut montrer par une analyse de Fourier (analyse de von Neumann) que le schéma est **stable si et seulement si** le nombre de Courant satisfait :

$$\nu = \frac{c\tau}{h} \leq 1 \quad \Longleftrightarrow \quad \tau \leq \frac{h}{c}$$

Cette CFL stricte traduit le fait, là encore, que la vitesse de propagation numérique $\frac{h}{\tau}$ doit être supérieure ou égale à la vitesse de propagation physique de l'onde c .

Explication / Idée : Erreur de Consistance

L'erreur globale du schéma est définie par $e := \max_{j,n} |u(x_j, t_n) - u_j^n|$. Comme nous avons employé des différences finies centrées d'ordre 2, aussi bien pour la dérivée seconde spatiale que pour la dérivée seconde temporelle, l'erreur du schéma se comporte de la manière suivante :

$$e = \mathcal{O}(h^2 + \tau^2)$$

Ce qui fait de cette méthode un schéma consistant d'ordre 2 en espace et en temps.

13 Semaine 13 - Introduction aux Éléments Finis

Cette section introduit la transition des méthodes de différences finies vers la formulation variationnelle nécessaire à la construction de la méthode des éléments finis (MEF).

13.1 Limites de la méthode des différences finies

On considère le problème unidimensionnel aux limites de Dirichlet homogènes suivant : trouver une fonction $u : [0, 1] \rightarrow \mathbb{R}$ telle que :

$$\begin{cases} -u''(x) = f(x) & 0 < x < 1 \\ u(0) = u(1) = 0 \end{cases} \quad (15)$$

Pour résoudre ce problème de manière numérique par la méthode des différences finies, on commence par partitionner l'intervalle $[0, 1]$ de manière uniforme avec un pas de discrétisation $h = \frac{1}{N+1}$:

$$0 = x_0 < x_1 < \dots < x_{N+1} = 1, \quad \text{avec } x_j = jh$$

L'approximation classique du terme de dérivée seconde par un schéma centré conduit au système de différences finies suivant :

$$\begin{cases} \frac{-u_{i-1} + 2u_i - u_{i+1}}{h^2} = f(x_i), & i = 1, \dots, N \\ u_0 = u_{N+1} = 0 \end{cases} \quad (16)$$

Théorème : Convergence des différences finies

Si la solution exacte u est de classe $C^4([0, 1])$, alors il existe une constante $C > 0$ indépendante de h telle que :

$$\max_{j=1, \dots, N} |u(x_j) - u_j| \leq Ch^2$$

Une question fondamentale se pose alors quant à la robustesse et aux exigences de cette méthode.

Explication / Idée : Questions ouvertes

1. Que se passe-t-il si la solution exacte $u \notin C^4([0, 1])$?
2. Que se passe-t-il si la source de charge f n'est pas continue sur $[0, 1]$?

Considérons les deux exemples illustratifs suivants où la régularité classique fait défaut.

Exemple : Cas de non-régularité

Exemple 1 : Charge discontinue (fonction créneau)

$$f(x) = \begin{cases} -1 & \text{si } 0 < x \leq \frac{1}{2} \\ 1 & \text{si } \frac{1}{2} < x < 1 \end{cases}$$

Ici, f présente un saut de discontinuité franc en $x = \frac{1}{2}$.

Exemple 2 : Charge impulsionnelle (Dirac)

$$f(x) = \delta(x - 1/2)$$

La "fonction" de Dirac n'est pas définie au sens usuel des fonctions classiques, mais uniquement au sens des distributions (elle est mal définie ponctuellement).

13.2 Méthode des éléments finis et formulation faible

Pour surmonter ces contraintes de régularité forte, nous introduisons la formulation variationnelle.

Repartons de l'équation forte $-u''(x) = f(x)$ sur $0 < x < 1$.

Soit $v : [0, 1] \rightarrow \mathbb{R}$ une fonction de test arbitraire. Multiplions l'équation différentielle par $v(x)$ puis intégrons sur l'intervalle $[0, 1]$:

$$\int_0^1 -u''(x)v(x) dx = \int_0^1 f(x)v(x) dx$$

En effectuant une intégration par parties du terme de gauche, on utilise la formule classique d'intégration par parties :

$$\int_0^1 g'(x)h(x) dx = [g(x)h(x)]_0^1 - \int_0^1 g(x)h'(x) dx$$

En choisissant $g' = u''$ (d'où $g = u'$) et $h = v$, on obtient :

$$\int_0^1 -u''(x)v(x) dx = [-u'(x)v(x)]_0^1 + \int_0^1 u'(x)v'(x) dx$$

Afin d'éliminer le terme de bord, nous choisissons les fonctions de test v de sorte qu'elles s'annulent aux frontières, c'est-à-dire $v(0) = v(1) = 0$. Comme nous imposons également les conditions limites homogènes sur u ($u(0) = u(1) = 0$), nous obtenons :

$$[-u'(x)v(x)]_0^1 = -u'(1)\underbrace{v(1)}_{=0} + u'(0)\underbrace{v(0)}_{=0} = 0$$

Ceci conduit naturellement à la **formulation variationnelle** (ou formulation faible) du problème (15).

Définition : Formulation faible

Trouver $u \in V$ tel que :

$$\int_0^1 u'(x)v'(x) dx = \int_0^1 f(x)v(x) dx \quad \forall v \in V \quad (17)$$

Mais quel est exactement l'espace fonctionnel V adéquat pour définir ce problème ?

Définition : Espace des déformations admissibles V

Dans un cadre classique simplifié, on définit l'espace fonctionnel V par :

$$V = \{v : [0, 1] \rightarrow \mathbb{R} \text{ continue, } v' \text{ continue par morceaux sur } [0, 1], v(0) = v(1) = 0\}$$

Cet espace est couramment appelé **l'espace des déformations admissibles**.

Remarque : Interprétation moderne et énergétique

- **Supplément de rigueur** : Dans un cadre d'analyse moderne et rigoureux, V est défini comme l'espace de Sobolev $H_0^1(0, 1)$ fondé sur l'espace de Lebesgue $L^2(0, 1)$.
- **Équivalence des solutions** :
 1. Si le problème fort (15) admet une solution unique de classe $C^2([0, 1])$, alors cette fonction u est également l'unique solution de la formulation faible (17).
 2. Réciproquement, il existe des solutions faibles à la formulation (17) qui ne possèdent pas la régularité suffisante pour satisfaire le problème fort (15) au sens ponctuel classique.
- **Formulation énergétique** : Si l'on choisit la fonction de test $v = u$ dans (17), on obtient l'égalité physique :

$$\underbrace{\int_0^1 (u'(x))^2 dx}_{\text{Énergie de déformation}} = \underbrace{\int_0^1 f(x)u(x) dx}_{\text{Travail des forces}}$$

13.3 Méthode de Galerkin

L'espace V est un espace vectoriel de dimension infinie. Si $\{\psi_j\}_{j \geq 1}$ est une base dénombrable de V , on peut décomposer toute solution $u(x) \in V$ sous la forme :

$$u(x) = \sum_{j=1}^{\infty} c_j \psi_j(x)$$

Ce problème possède une infinité de coefficients c_j à déterminer, ce qui est impossible à résoudre numériquement de manière directe.

L'**idée clé** de la méthode de Galerkin consiste à projeter la formulation variationnelle sur un sous-espace vectoriel de dimension finie $V_h \subset V$, tel que $\dim(V_h) = N < \infty$. On cherche alors une approximation $u_h \in V_h$ de la solution exacte u .

Le paramètre $h \approx \frac{1}{N+1} > 0$ correspond au pas de la discrétisation spatiale, et l'on s'assure que $u_h \rightarrow u$ lorsque $h \rightarrow 0$ (c'est-à-dire $N \rightarrow \infty$).

Soient $\varphi_1, \dots, \varphi_N \in V$ des fonctions linéairement indépendantes définissant le sous-espace :

$$V_h = \text{Vect}\{\varphi_1, \dots, \varphi_N\} = \left\{ \sum_{j=1}^N \alpha_j \varphi_j(x) \mid \alpha_j \in \mathbb{R} \right\}$$

Définition : Discrétisation de Galerkin

Le problème variationnel discret s'énonce ainsi : trouver une fonction $u_h \in V_h$ telle que :

$$\int_0^1 u_h'(x) v_h'(x) dx = \int_0^1 f(x) v_h(x) dx \quad \forall v_h \in V_h \quad (18)$$

Par linéarité de l'intégrale, satisfaire cette relation pour toute fonction $v_h \in V_h$ équivaut à la satisfaire uniquement pour chaque fonction de la base génératrice $\{\varphi_i\}_{i=1}^N$. Le problème revient donc à trouver $u_h \in V_h$ vérifiant :

$$\int_0^1 u_h'(x) \varphi_i'(x) dx = \int_0^1 f(x) \varphi_i(x) dx \quad \forall i = 1, \dots, N \quad (19)$$

Puisque la solution approchée u_h appartient à V_h , elle se décompose sur cette même base :

$$u_h(x) = \sum_{j=1}^N u_j \varphi_j(x)$$

La recherche de la fonction u_h se ramène ainsi à la détermination des N coefficients réels $\{u_j\}_{j=1}^N$.

En injectant cette décomposition dans l'équation, pour tout indice i fixé :

$$\begin{aligned} \int_0^1 f(x) \varphi_i(x) dx &= \int_0^1 u_h'(x) \varphi_i'(x) dx = \int_0^1 \left(\sum_{j=1}^N u_j \varphi_j'(x) \right) \varphi_i'(x) dx \\ &= \int_0^1 \left(\sum_{j=1}^N u_j \varphi_j'(x) \right) \varphi_i'(x) dx \\ &= \sum_{j=1}^N u_j \underbrace{\int_0^1 \varphi_j'(x) \varphi_i'(x) dx}_{A_{ij}} \end{aligned}$$

En posant $A_{ij} = \int_0^1 \varphi_j'(x) \varphi_i'(x) dx$ et $f_i = \int_0^1 f(x) \varphi_i(x) dx$, on obtient :

$$\sum_{j=1}^N A_{ij} u_j = f_i \quad \forall i = 1, \dots, N$$

Le vecteur des inconnues $\vec{u} = [u_1 \quad u_2 \quad \dots \quad u_N]^T$ est l'unique solution du système linéaire algébrique :

$$A \vec{u} = \vec{f} \quad (20)$$

Proposition : Propriétés de la matrice A

La matrice $A \in \mathbb{R}^{N \times N}$ est appelée **matrice de rigidité**. On montre facilement qu'elle est :

- **Symétrique** : $A_{ij} = A_{ji}$ par symétrie du produit scalaire de L^2 .
- **Définie positive** : pour tout vecteur non nul $\vec{v}$, $\vec{v}^T A \vec{v} = \int_0^1 (v_h'(x))^2 dx > 0$.

Par conséquent, la matrice A est inversible, ce qui garantit que le système linéaire (20) admet une

unique solution.

13.4 Choix des fonctions de base et fonctions chapeau

Il existe plusieurs options pour le choix des fonctions de base $\{\varphi_j\}_{j=1}^N$:

1. **Base trigonométrique** : $\varphi_j(x) = \sin(j\pi x)$, $j = 1, \dots, N$.
2. **Base polynomiale classique** : $\varphi_j(x) = x^j(1 - x)$, $j = 1, \dots, N$.

Remarque : Abandon historique

Cette base polynomiale a été historiquement utilisée lors des premiers calculs, mais rapidement abandonnée car elle engendre des matrices A pleines et extrêmement mal conditionnées (les calculs deviennent très complexes et numériquement instables).

3. **Fonctions polynomiales par morceaux** : C'est la base de la méthode des éléments finis moderne. On considère ici le cas de fonctions affines par morceaux (souvent appelées fonctions *chapeau*).

Le domaine $[0, 1]$ est découpé avec les points de discrétisation $x_j = jh$ pour $h = \frac{1}{N+1}$. Chaque fonction de base $\varphi_j(x)$ est construite de façon à valoir 1 au nœud x_j et 0 en tous les autres nœuds x_i ($i \neq j$).




Figure 1: Représentation schématique des fonctions de base chapeau $\varphi_j(x)$ (Éléments Finis P_1).

L'expression analytique de la fonction chapeau $\varphi_j(x)$ s'écrit :

$$\varphi_j(x) = \begin{cases} \frac{x-x_{j-1}}{h} & \text{si } x_{j-1} \leq x \leq x_j \\ \frac{x_{j+1}-x}{h} & \text{si } x_j \leq x \leq x_{j+1} \\ 0 & \text{sinon} \end{cases} \quad (21)$$

Les dérivées de ces fonctions de base sont constantes par morceaux :

$$\varphi_j'(x) = \begin{cases} \frac{1}{h} & \text{si } x_{j-1} < x < x_j \\ -\frac{1}{h} & \text{si } x_j < x < x_{j+1} \\ 0 & \text{sinon} \end{cases} \quad (22)$$




Figure 2: Représentation de la dérivée première $\varphi'_j(x)$ de la fonction chapeau.

13.5 Calcul de la matrice de rigidité et du second membre

Calculons les coefficients $A_{ij} = \int_0^1 \varphi'_i(x) \varphi'_j(x) dx$:

- **Cas $i = j$ (Diagonale) :**

$$A_{j,j} = \int_{x_{j-1}}^{x_{j+1}} (\varphi'_j(x))^2 dx = \int_{x_{j-1}}^{x_j} \left(\frac{1}{h}\right)^2 dx + \int_{x_j}^{x_{j+1}} \left(-\frac{1}{h}\right)^2 dx = \frac{1}{h^2}(h) + \frac{1}{h^2}(h) = \frac{2}{h}$$

- **Cas $i = j - 1$ (Sous-diagonale) :**

$$A_{j-1,j} = \int_{x_{j-1}}^{x_j} \varphi'_{j-1}(x) \varphi'_j(x) dx = \int_{x_{j-1}}^{x_j} \left(-\frac{1}{h}\right) \left(\frac{1}{h}\right) dx = -\frac{1}{h^2}(h) = -\frac{1}{h}$$

- **Cas $i = j + 1$ (Sur-diagonale) :**

$$A_{j+1,j} = \int_{x_j}^{x_{j+1}} \varphi'_{j+1}(x) \varphi'_j(x) dx = \int_{x_j}^{x_{j+1}} \left(\frac{1}{h}\right) \left(-\frac{1}{h}\right) dx = -\frac{1}{h^2}(h) = -\frac{1}{h}$$

- **Cas $|i - j| > 1$:** Puisque les supports de φ_i et φ_j ne s'intersectent pas (d'intersection presque partout nulle), on obtient immédiatement :

$$A_{ij} = 0$$

La matrice de rigidité globale $A \in \mathbb{R}^{N \times N}$ est donc une matrice tridiagonale hautement creuse de la forme suivante :

$$A = \frac{1}{h} \begin{bmatrix} 2 & -1 & 0 & \dots & 0 \\ -1 & 2 & -1 & \ddots & \vdots \\ 0 & -1 & 2 & \ddots & 0 \\ \dots & \ddots & \ddots & \ddots & -1 \\ 0 & \dots & 0 & -1 & 2 \end{bmatrix} \quad (23)$$

Calculons à présent les composantes du vecteur second membre f_i :

$$f_i = \int_0^1 f(x) \varphi_i(x) dx = \int_{x_{i-1}}^{x_{i+1}} f(x) \varphi_i(x) dx = \int_{x_{i-1}}^{x_i} f(x) \varphi_i(x) dx + \int_{x_i}^{x_{i+1}} f(x) \varphi_i(x) dx$$

Si l'on ne peut pas intégrer de manière analytique exacte ces intégrales, on emploie la **méthode des trapèzes** sur chacun de ces deux intervalles d'intégration pour approximer numériquement le résultat :

$$\int_{x_{i-1}}^{x_i} f(x) \varphi_i(x) dx \approx \frac{h}{2} \left(f(x_{i-1}) \underbrace{\varphi_i(x_{i-1})}_{=0} + f(x_i) \underbrace{\varphi_i(x_i)}_{=1} \right) = \frac{h}{2} f(x_i)$$

$$\int_{x_i}^{x_{i+1}} f(x) \varphi_i(x) dx \approx \frac{h}{2} \left(f(x_i) \underbrace{\varphi_i(x_i)}_{=1} + f(x_{i+1}) \underbrace{\varphi_i(x_{i+1})}_{=0} \right) = \frac{h}{2} f(x_i)$$

En additionnant ces deux contributions, on obtient l'approximation suivante du second membre :

$$f_i \approx \frac{h}{2} f(x_i) + \frac{h}{2} f(x_i) = h f(x_i) \quad (24)$$

En réinjectant (24) dans le système linéaire $A\vec{u} = \vec{f}$, on retrouve :

$$\frac{-u_{i-1} + 2u_i - u_{i+1}}{h} = h f(x_i) \iff \frac{-u_{i-1} + 2u_i - u_{i+1}}{h^2} = f(x_i)$$

On constate ainsi une équivalence remarquable avec le système issu des différences finies (DF).

13.6 Comparaison : Éléments Finis (EF) vs Différences Finies (DF)

Exemple : Avantages comparatifs des Éléments Finis

Bien que le système discret linéaire obtenu soit identique dans ce cas unidimensionnel académique simple avec la formule des trapèzes, les Éléments Finis apportent une rigueur et une souplesse considérables par rapport aux Différences Finies :

- **Plus grande liberté géométrique** : La MEF gère très naturellement les maillages non uniformes en 1D ainsi que les géométries bidimensionnelles ou tridimensionnelles extrêmement complexes (triangles, tétraèdres).
- **Moindre exigence de régularité** : La méthode ne requiert pas de régularité forte sur la solution (C^4 pour les DF) ni sur le second membre f .
- **Estimations d'erreurs plus faibles** : Les estimations de convergence sont exprimées en norme d'énergie (norme H^1 ou L^2) beaucoup plus adaptées à la physique plutôt qu'en norme infinie C^0 ponctuelle.
- **Adaptivité locale** : Elle permet de raffiner localement le maillage (ajouter plus d'éléments là où la solution varie brutalement et moins là où elle est lisse) de manière très naturelle.

13.6.1 Synthèse graphique : DF vs EF

Cette figure résume la différence fondamentale de philosophie entre l'approche purement discrète ponctuelle (DF) et l'approche variationnelle géométrique (EF).




Figure 3: Comparaison des approches de discrétisation spatiale : rigidité structurée des Différences Finies (à gauche) contre flexibilité géométrique des Éléments Finis triangulaires (à droite).